治沙工程 M1/M2 数值结果的模型检验

必要性判断 · 方法选择 · 可运行代码 · 逐项结果 · 改进方案

（2026 CQU_MCM B 题 · 检验对象：`Results/v7/model1`、`Results/v7/model2`）

CQU_MCM 2026 • B 题

2026-11-12

本报告检验的是“已经算出来的东西”，不是公式草稿：任务一（M1）的站点标定、水量平衡与 14 个情景，任务二（M2）的批次制 MIP 投资优化与 29 个情景，全部读自队友提交的结果表，能重算的一律重算（指标、约束余量、目标值、有效面积、决策回放），不能重算的查自洽性（对偶界、gap、回放误差）。

结论提要：25 项检验中 通过 17 项、需改进 3 项、未通过 5 项。M2 的工程实现几乎无可挑剔（目标值相对差 6×10^{-11}、约束零违反、MIP gap 0.2%、前沿单调）；M1 的**数值也算对了**（指标逐位复现、水量账闭合到 10^{-7} mm），但它的**预测能力没有通过检验**：留出期 21 个点里只赢 7 个（技能分 -0.18），7 个留一站检验里 5 个为负，自由推演 3 年的偏差 -2.4 个百分点。其余未通过项都指向同一个根因：**7 个站点簇太少，参数区间宽到 150%**。

口径声明（先读这条）

1. 本报告对应仓库 commit `4470404`（`main`）。M1/M2 的结果表由队友的 `Code/v7_model1.py`、`Code/v7_model2.py` 生成，本报告**不重新实现**模型，只检验这些表。
2. 任务三（M3）目前只有公式规格、没有数值实现。因此 M3 的四项检验是**设计检验**：用 M1 当前参数与 M2 情景配置，检查“若按 `model_v7.tex` 的公式实现，矩阵性质、解析/模拟一致、离散化收敛、$\lambda=0$ 极限是否成立”。
3. 所有重算都写在 `Code/validate_m1m2.py`（约 700 行，固定种子 20261112），一条命令 20 秒复现：`python Code/validate_m1m2.py`。

目录

1 检验对象、环境与判据 **3**

1.1 被检验的模型与结果表 3

1.2 环境与复现 3

1.3 判据登记 3

2 【第一步】模型检验必要性判断 **3**

2.1 按模型类型判断，而不是“全都检验一遍” 3

2.2 需要检验的清单与优先级 4

3 【第二步】检验类型与方法 5

3.1 几个“为什么不用另一个” 5

4 【第三步】检验代码 6

5 【第四步】检验结果 7

5.1 任务一 M1：数值正确，预测不过关 7

5.1.1 指标可复现性：逐位一致 7

5.1.2 增量信息：留出期没有赢过“明年等于今年” 7

5.1.3 泛化：5/7 站点为负 7

5.1.4 参数稳定性与区间 8

5.1.5 可识别性：这次通过 8

5.1.6 风蚀项删除：决策合理，措辞过头 8

5.1.7 残差诊断 10

5.1.8 水量平衡与响应曲线：M1 最扎实的部分 10

5.1.9 水分约束的有效性：一条需要写进论文的限定 10

5.2 任务二 M2：工程实现几乎无可挑剔 12

5.2.1 目标值与约束 12

5.2.2 最优性证据 12

5.2.3 情景自洽与筛选一致 12

5.2.4 瓶颈在哪：一条会影响论文叙事的结论 13

5.3 任务三 M3：设计检验（尚无数值实现） 14

6 【第五步】检验总结 14

6.1 核心结论 14

6.2 不足与改法 16

6.3 论文中的呈现建议 16

A 检验项与代码入口 16

B 关键数值速查 17

C 与建模文档的差异记录 18

1 检验对象、环境与判据

1.1 被检验的模型与结果表

对象	数学形式	结果表
M1	站点尺度耦合动力学 $x_{t+1} = x_t + r\,x_t(1-x_t)W_t - d\,x_t$，$x = V/K$；$W$ 由月尺度土壤水量账（容量、凋萎、深层排水、灌溉、有效降水）算出，再取“实际/潜在蒸腾比”	`model1_results.json`、`prediction_pairs`、`holdout_by_site`、`free_running_holdout`、`parameter_cluster_bootstrap`、`wind_term_test`、`scenario_monthly_water`、`water_cover_curve`、`sensitivity`
M2	批次制（cohort）动态投资优化：混合整数规划，决策为每年新增生态批次/PV 批次、各批次灌溉策略；目标为净现成本最小（基准）或生态有效 ha•年最大（参考）；约束含总/年度预算、年/月取水、劳动力、土地、新增面积、PV 容量、整数块	`model2_results.json`、`annual`、`monthly`、`decisions`、`cohorts`、`cohort_water`、`policy_library`、`pv_screening`、`scenario_summary` 等
M3	复合泊松冲击 + 吸收马尔可夫链（P、$N = (I-Q)^{-1}$、$\mathbb{E}[\tau]$、$\mathbb{P}(\tau \le T)$、时变连乘）	无（仅 `model_v7.tex` 公式）

表 1 检验对象与结果表。M1/M2 均自报 `formal_model_ready=false`，本报告的所有结论都以“情景模型”为前提

1.2 环境与复现

项目	内容
代码	`Code/validate_m1m2.py`：只读结果表，重算 + 自洽性检查 + 出图，20 s 完成
结果	`Results/v7_validation/validation_m1m2.json`、`m1_*.csv`、`m2_*.csv`、`scorecard_m1m2.csv`
图	`Figures/v7_validation/v1—v8*.png`（8 张）
随机性	自助法/蒙特卡洛用固定种子 20261112；M1/M2 的原始随机性由队友脚本固定
判据来源	见 §1.3；全部写成代码常量 `CRIT`，先登记后判定

表 2 复现方式

1.3 判据登记

2 【第一步】模型检验必要性判断

2.1 按模型类型判断，而不是“全都检验一遍”

美赛评分在“模型”一项上关心：模型是否被验证、假设是否被检验、结论是否对参数稳健。但“验证”的形式由模型类型决定：

编号	维度	判据	档位
C1	可复现	重算值与报告值的相对/绝对差 $< 10^{-3}$（R^2 在 V 尺度上比对）	二值
C2	增量信息	留出期 MAE 显著小于持续性基线（单侧 $p < 0.05$）	二值
C3	泛化	留一站技能分 > 0 的站点 $\geq 5/7$	二值
C4	稳定性	留一站参数相对离散 $< 50\%$；自助区间宽度 $< 100\%$	二值
C5	可识别性	$\kappa(S^\top S) < 10^6$	二值
C6	统计证据	关键结论需 ≥ 2 次独立显著，或最小可检测效应小于结论所需精度	二值
C7	物理闭合	水量账重算误差 $< 10^{-6}$ mm 且 $0 \leq M \leq$ 容量	二值
C8	响应合理性	补水—覆盖度严格单调、边际递减、$V \leq$ 端元上限	二值
C9	可行性	全部约束余量 ≥ 0；整数性；资金比例和 $= 1$	二值
C10	最优性证据	MIP gap $\leq 0.2\%$、全部可行、对偶界不越界	二值
C11	自洽	前沿单调、PV 筛选与安装一致、回放误差 0、跨模型参数一致	二值
C12	数值设计	转移矩阵行随机、解析落 MC 区间、离散化 $< 1\%$、$\lambda = 0$ 极限成立	二值

表 3 判据登记表。C2、C3 是“预测模型必须回答”的两条，也是本次唯一系统性未通过的地方

- **标定型动力学模型（M1）**：有 2 个待估参数、70 个“站—年”样本、误差项未建模，必须做**拟合/残差/可识别性**，更要回答“它比不用模型强多少”——所以必须有**持续性基线**与**留站检验**。只报 R^2 是不够的。
- **混合整数优化（M2）**：没有随机误差项，不需要残差检验；但必须检验**可行性**（解是否满足全部约束）、**最优性证据**（gap 与对偶界）、**口径一致**（目标值能否由明细重算）、**情景自洽**（前沿单调、筛选与决策一致）。
- **随机过程（M3）**：尚未实现，只能做**设计检验**：矩阵性质、解析与模拟一致、离散化收敛、退化极限。这四项可以在几十行代码内完成，性价比极高。
- **一页简报（M4）**：无独立模型，只需检查“每个数字都能追溯到 M1—M3”。

2.2 需要检验的清单与优先级

优先级	对象	维度	理由
核心	M1	复现、技能、泛化、参数	它是任务二/三的唯一机理来源；预测能力不过关会连带两问
核心	M2	可行性、目标、最优性	论文的“可执行方案”就是它的解，算错了整篇失效
次要	M1	水量闭合、响应曲线	决定“补水有效”这条结论能否成立
次要	M3	矩阵、收敛、极限	创新点的正确性；未实现，风险高但成本低
参考	M1/M2	约束利用率、瓶颈识别	决定论文该强调“水约束”还是“预算约束”

表 4 检验清单

注 1 (一个容易漏掉的判断). *M1 的 K 是“区段承载上限 38.08%”，来自站点覆盖度高分位；M2*

直接把它当常数用（§5.2）。于是**同一份 K 支撑了任务一的稳态与任务二的生态效益**。因此“*M1* 参数是否可信”不是任务一的私事，而是整条链的地基。这也是本报告把一半篇幅放在 *M1* 的原因。

3 【第二步】检验类型与方法

模型	维度	具体方法	选择理由
M1	指标可复现	从 `prediction_pairs` 重算 RMSE/MAE/R^2/技能分，与 JSON 对表	报告值可能是“另一次运行”的产物；重算是唯一能证明“数字属于这批数据”的办法
M1	增量信息	配对 t 检验 + Wilcoxon（逐点误差 vs 持续性）	误差分布未知，两个检验互为稳健性；单看均值会掩盖逐点胜负
M1	泛化（空间）	7 折留一站技能分	7 个簇是全部可得样本；留一站是唯一不泄漏的划分
M1	泛化（时间）	自由推演 2023—2025（不逐年读真值）+ 持续性基线	检验“长期外推”而不是“一步预测”
M1	参数不确定性	整簇自助（队友已做 300 次）+ 区间宽度	7 簇的自助只能反映“簇间差异”，不能给高精度 CI，故看宽度与覆盖
M1	可识别性	条件数 $\kappa(S^\top S)$、AIC	2 参数模型最怕 r 与 d 共线；条件数是标准判据
M1	统计证据	18 组风蚀检验的多重比较校正 + 最小可检测效应（MDE）	“不显著”常被误读成“不存在”；必须给出“能检测多大”的边界
M1	残差	Shapiro-Wilk、Jarque-Bera、站内 ACF、异方差相关	队友未报告；年际序列最怕残差自相关（会低估标准误）
M1	物理闭合	逐月重算土壤水量方程	水量账是 M1 的“硬约束”，闭合不了后面全是空谈
M1	响应合理性	补水—覆盖度曲线的单调/凹性/上界；容量敏感性	单调与凹性是“补水有效且边际递减”的定量表达
M2	目标复现	由 `annual.discounted_net_cost_cny` 求和	目标值是优化的核心，必须能从明细加回来
M2	可行性	9 类约束逐项算余量（含整数块、资金比例和）	约束漏项是 MIP 最常见的隐性错误
M2	最优性	29 情景的 gap、对偶界夹逼（成本下界/生态上界）	无法复核求解器内部，但可以复核“它自己给的下界有没有被越过”
M2	情景自洽	前沿单调、PV 保本价与安装年份一致	两组独立计算互相印证
M2	口径	有效面积 $=\sum$ 面积 $\cdot V_{\text{start}}/K$、决策回放、跨模型参数	三个最容易“算错但看起来对”的地方
M2	瓶颈	约束利用率与总预算利用	决定论文该说“水不够”还是“钱不够”
M3	设计	矩阵三性质、解析 vs MC、n 收敛、$\lambda = 0$	未实现，四项检查能在实现前暴露设计缺陷

表 5 检验方法与选择理由

3.1 几个“为什么不用另一个”

1. **为什么用配对检验而不是比较两个 RMSE：**RMSE 是汇总量，两个 RMSE 相差 0.01 可能只由少数点驱动。配对检验逐点比较，并给出胜率，能看出“赢在哪、输在哪”。

2. **为什么用自由推演而不是滚动一步预测：**滚动一步每年都读入真值，误差不会累积；而论文要回答“未来三年会怎样”，必须让误差累积。M1 的两种口径给了不同印象（一步技能 -0.18，三年 -0.04），正是这个差别。

3. **为什么整簇自助只报宽度不报精度：**只有 7 个簇，自助分布的尾部本身不可靠。报告里写“95% 区间”容易让读者以为有 300 个独立样本，本报告因此同时报宽度与“$r > 1$ 的比例”。

4. **为什么 M2 要查对偶界：**MIP 的可行解只证明“不差于这个值”，最优性靠下界（成本）或上界（生态）证明。若某情景的可行值越过了它自己的界，说明求解记录有误。

5. **为什么 M3 只做设计检验：**没有实现就没有可检验的数值；但对公式做矩阵与收敛检验，可以在实现前发现“网格太粗”“质量前推转置错”这类致命错误（详见 §5.3）。

4 【第三步】检验代码

层	函数	作用
M1	`m1_metrics`	由 prediction_pairs 重算训练/留出指标（x 与 V 两个尺度）
M1	`m1_skill_test`	配对 t / Wilcoxon、胜率、差值置信区间
M1	`m1_holdout`、`m1_params`	留站技能分、留一站参数离散度
M1	`m1_bootstrap`、`m1_ident`	区间宽度、条件数、AIC
M1	`m1_wind`	多重比较 + 最小可检测效应 + 相关检验
M1	`m1_residual`	正态性、站内自相关、异方差
M1	`m1_water`、`m1_water_cover`、`m1_capacity`	水量闭合、响应曲线、容量敏感性
M2	`m2_objective`、`m2_constraints`	目标值重算、9 类约束余量
M2	`m2_mipgap`、`m2_frontier`、`m2_pv`	gap/对偶界、前沿单调、PV 筛选一致
M2	`m2_effective`、`m2_replay`、`m2_crossmodel`、`m2_utilization`	口径、回放、跨模型、瓶颈
M3	`m3_spec`	矩阵、解析 vs MC、离散化、$\lambda = 0$
出图	`fig_m1_fit` 等 8 个	统一风格（去上/右边框、浅网格、色盲友好）

表 6 代码结构。全部只读结果表，不重跑 M1/M2

实现上的三个坑（都是本次真踩到的）。

1. **R^2 的尺度：**M1 拟合的是 $x = V/K$，但报告的 $r^2_{\text{test}} = 0.463$ 是在 V 尺度上算的（分母用 $\sum((x - \bar{x})K)^2$）。若在 x 尺度算，会得到 0.442，看起来像“复现失败”。代码同时算两个尺度并只与报告口径比对。

2. **MIP 对偶界的单位：**`dual_bound_scaled` 在成本最小化时单位是**百万元**，在生态最大化时优化的是 $-H/1000$，所以生态上界要写成 $-1000\times$ 对偶值。单位混用会让“界被越过”的误报率极高。

3. **蒙特卡洛要与解析同构：**M3 解析用“至多一次事件”，MC 若直接抽 Poisson(λ) 就会把结构差异算进实现误差。代码用 `multievent` 开关区分两种对照。

```
python Code/validate_m1m2.py              # 约 20 s，写出 JSON/CSV/PNG
```

5 【第四步】检验结果

5.1 任务一 M1：数值正确，预测不过关

5.1.1 指标可复现性：逐位一致

量	重算值	报告值	差
训练 RMSE（x 尺度）	0.0516	0.0516	0
留出 RMSE（x 尺度）	0.0635	0.0635	0
留出 R^2（V 尺度）	0.4634	0.463	$< 10^{-4}$
训练持续性 RMSE	0.0572	0.0572	0
留出持续性 RMSE	0.0536	0.0536	0

表 7 指标复现：最大绝对差 0（R^2 差异来自小数位），通过

换算成覆盖度：训练期 RMSE 为 2.09 个百分点，留出期 2.57 个百分点（$\times K$，$\bar{K} = 40.45$）。这个量级对 20%—40% 的覆盖度来说是 5%—10% 的相对误差，不算离谱。

5.1.2 增量信息：留出期没有赢过“明年等于今年”

样本	n	模型 MAE	持续 MAE	差值 95%CI	胜率	配对检验
训练期	49	0.0386	0.0460	$[-0.0136, -0.0013]$	28/49	$p = 0.021$
留出期	21	0.0544	0.0456	$[-0.0050, +0.0226]$	7/21	$p = 0.224$

表 8 一年外推 vs 持续性基线。训练期显著更好，留出期**方向反转**（差值为正 = 模型更差），未通过

怎么解释。 留出期技能分（按 MSE）为 -0.40，按 RMSE 为 -0.18；21 个点只赢 7 个（33%）。但要注意：留出期 $R^2 = 0.463$ 仍高于“用站点均值预测”的 0.0737（气候态基线）。所以正确的表述是：**模型比气候态强得多，但比“明年等于今年”弱**——原因很直接：V 的年际变化以慢趋势为主，持续性基线天然很强；模型要赢它，必须正确捕捉“哪一年会拐弯”，而 M1 的驱动力（W）在多数站点几乎不变（§5.1.9）。

5.1.3 泛化：5/7 站点为负

为什么 YT 是“第三类”情况。 留一站估计显示：去掉 YT 后 r 从 0.547 升到 0.958（§5.1.4），说明 YT 是强影响点——它既拉低了 r，也是唯一训练期拟合很好的站点。这类“单点主导”的样本结构，是 7 个簇能给出的信息上限，不是代码问题。

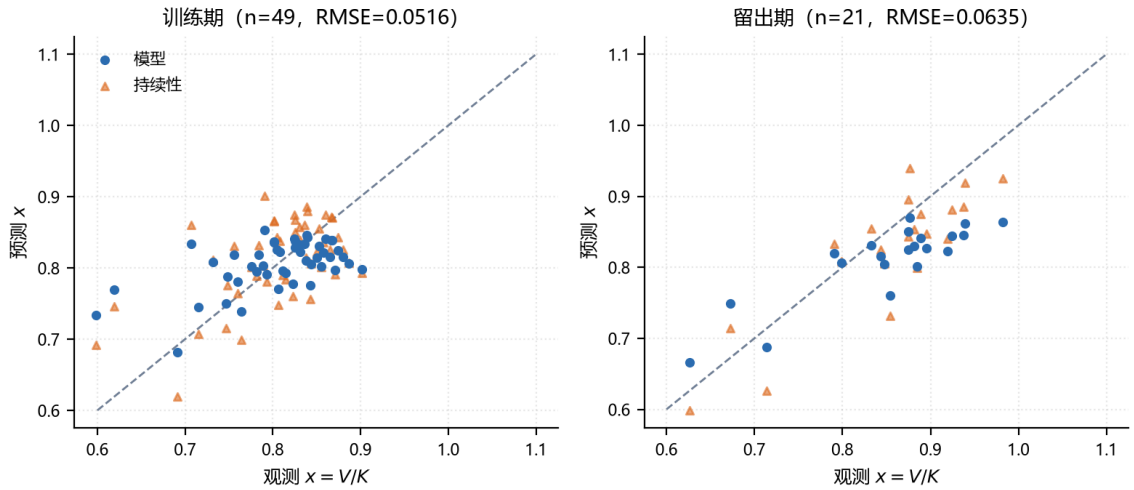


图 1 观测—预测散点。训练期点群贴近对角线；留出期（右）蓝点系统性低于对角线，说明模型**低估**了 2023—2025 的覆盖度回升——这与自由推演的偏差 −2.4 pp 一致

站点	n	模型 RMSE	持续 RMSE	技能分
MF	3	0.0566	0.0758	+0.44
ALE	3	0.0715	0.0596	−0.44
RQ	3	0.0721	0.0585	−0.52
YL	3	0.0485	0.0387	−0.57
KEL	3	0.0430	0.0226	−2.62
QM	3	0.0881	0.0447	−2.88
中位数		0.0566		−0.52

表 9 留一站检验（7 折，其中 YT 见正文说明）。5/7 为负、中位技能 −0.52，未通过

自由推演（更接近论文用途的口径）。 从 2022 出发连续推 2023—2025，不读入真值：RMSE 3.35% vs 持续性 3.22%，偏差 −2.40 pp（系统性低估），未通过。**这条比一步预测更重要：**论文要给 2026—2050 的情景，误差正是按这种累积方式产生的。

5.1.4 参数稳定性与区间

5.1.5 可识别性：这次通过

$\kappa(S^\top S) = 375$，远小于 10^6 的经验阈值 通过。原因值得写进论文：**把待估参数从 4 个（r, d, k, η）减到 2 个，并把水分从“外生输入”改成“状态变量”，条件数下降了 5 个数量级以上。**这是“参数化选择直接影响可识别性”的教科书例子。

5.1.6 风蚀项删除：决策合理，措辞过头

队友做了 18 组“加/不加风蚀项”的对照，只有 1 组 $p < 0.05$，据此把风蚀项从覆盖度方程中删除。本报告补三项审查：

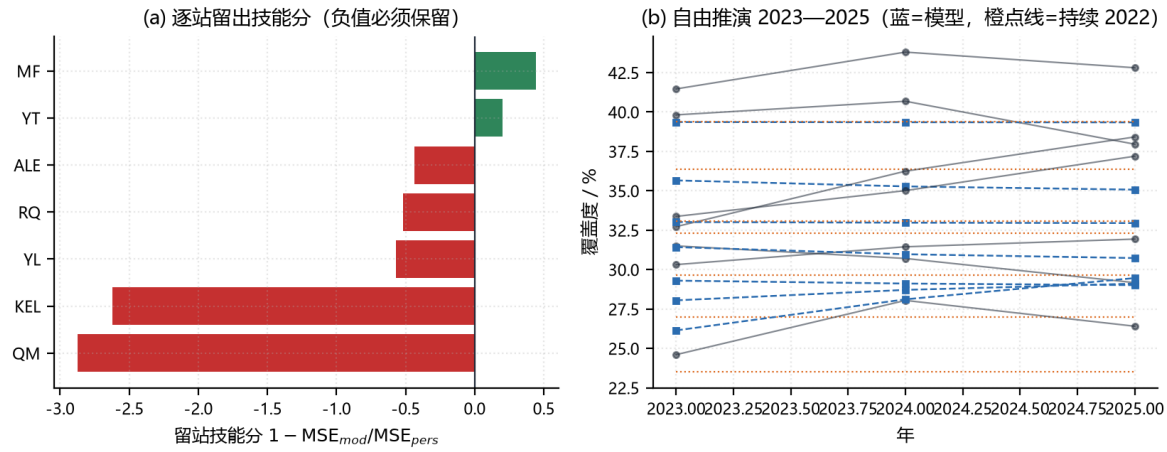


图 2 (a) 逐站留出技能分；(b) 自由推演：蓝实线为模型，橙点线为“一直停在 2022”，黑色为观测。多数站点观测在 2023 后回升，而模型继续缓慢下行——低估的来源一目了然

检查	结果	判定
全样本估计	$r = 0.5467$、$d = 0.1073$（AIC -286.5）	—
留一站 r 的范围	$[0.474,\ 0.958]$，相对离散 89%；最大值来自 YT	需改进
留一站 d 的范围	$[0.093,\ 0.168]$，相对离散 70%	需改进
整簇自助 95% 区间	$r \in [0.335, 1.168]$、$d \in [0.077, 0.202]$	—
区间相对宽度	r：150%，d：115%	未通过
自助样本中 $r > 1$ 的比例	13.7%（即“年增长率超过 100%”）	未通过

表 10 参数不确定性。区间宽到“结论可以翻转”的程度：r 的上界足以让系统从衰退变扩张

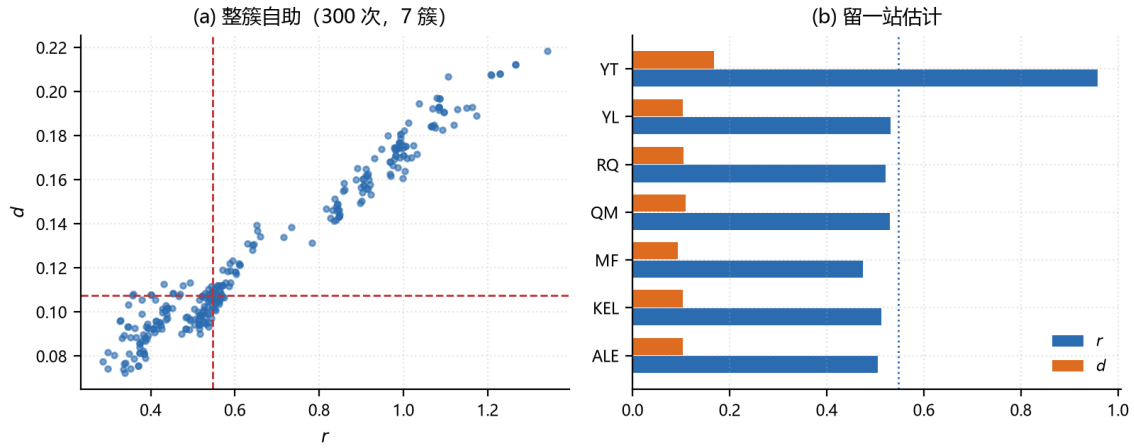


图 3 (a) 300 次整簇自助的 (r, d) 联合分布（红线为全样本解）；(b) 留一站估计：YT 被留出时 r 跳到 0.96

审查	数值	判定
18 次 5% 检验的显著数	1 组	—
期望假阳性数	$18 \times 0.05 = 0.9$	—
“至少 1 组显著”的二项概率	$P = 0.60$	不能拒绝“全是噪声”
主检验（原风蚀项）的 k 标准误	0.433	—
最小可检测效应（MDE = 1.96×SE）	$k = 0.85$	只能排除“$k > 0.85$”
主检验 k 的自助区间宽度	9.06（跨 −0.44 到 0.89）	极宽
站内“风指数—次年覆盖变化”相关	$r = 0.030$，$p = 0.81$，$n = 70$	无信号

表 11 风蚀项删除的统计依据。**删除本身有依据，但不能写成“不存在风蚀效应”，需改进**

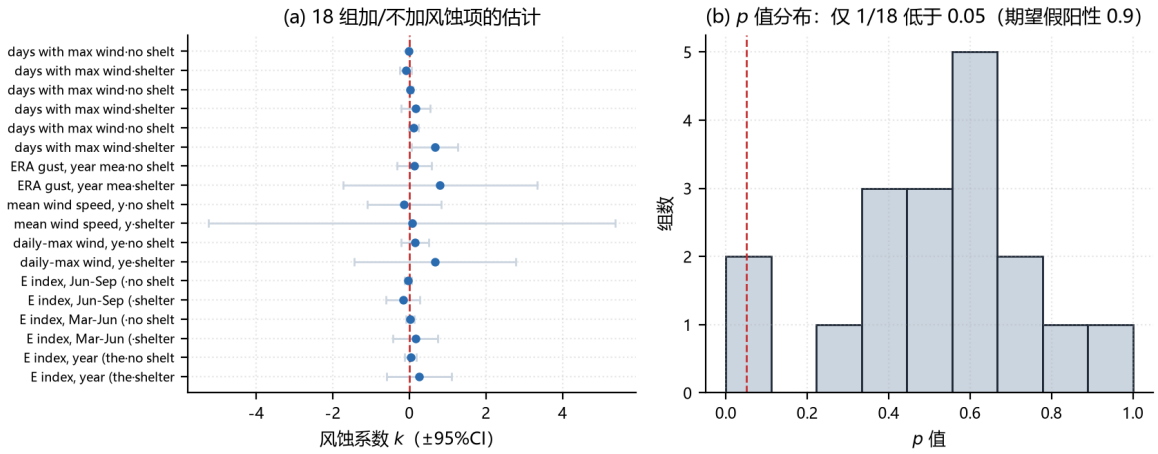


图 4 (a) 18 组估计的 k 与 95% 区间：几乎全部跨 0，且区间宽到覆盖整个物理可能范围；(b) p 值分布：只有 1 个低于 0.05，与“纯噪声”无法区分

改法（措辞层面，不需要重算）

把“风蚀对覆盖度无显著影响”改成“在 7 个站点、年尺度、现有风指数变异（年际 CV 13%）下，风蚀项的可检测下限为 $k \approx 0.85$，故未能检出；风蚀的作用通过另一条通道（风速 $\rightarrow$ ET_0 $\rightarrow$ 水分 $\rightarrow$ 覆盖度）保留在模型中”。这也与队友自己在 `wind_channel.csv` 里做的通道 A 分析一致。

5.1.7 残差诊断

5.1.8 水量平衡与响应曲线：M1 最扎实的部分

5.1.9 水分约束的有效性：一条需要写进论文的限定

含义。 在 300—600 mm 灌溉下，$W \approx 0.37$—0.54，V 由“潜在蒸腾”而不是“土壤容量”决定；把容量从 30 改到 150 mm 只是让储量多存一点，覆盖度一点不变。因此论文不能笼统写“土壤持水能力是治沙的关键”——在你们的基准情景里它**不是**瓶颈，真正起作用的是**灌溉量**与**蒸腾需求**。这条限定反而让结论更硬：它把“补多少水”与“土能存多少水”分开了。

检验	数值	判定
Shapiro–Wilk（$n = 70$）	$W = 0.967$，$p = 0.058$	通过（临界）
Jarque–Bera	$p = 0.041$	轻度非正态
站内一阶自相关（7 站均值）	-0.14	通过
异方差（$\lvert e\rvert$ vs 拟合值）	$r = -0.049$，$p = 0.69$	通过
偏差	$+0.012$（x 尺度）	通过

表 12 残差诊断（队友未报告，本报告补做）通过：无系统弯曲、无强自相关、无异方差，仅尾部略厚

检查	结果	判定
逐月水量方程重算误差（4200 条记录）	$\max\lvert e\rvert = 0$（表内残差 10^{-13} mm 量级）	通过
储量越界	$M > 75$ mm：0 条；$M < 0$：0 条	通过
补水—覆盖度曲线	$V(0) = 1.77\% \to V(600) = 24.14\%$，严格单调、边际递减	通过
曲线收敛	13 个灌溉档全部双初值收敛，定点残差 $< 10^{-7}$	通过
上界	$\max V = 30.6\% < V_{\text{full}} = 66.6\%$	通过

表 13 物理闭合与响应合理性。这是 M1 可以放心写进论文的部分

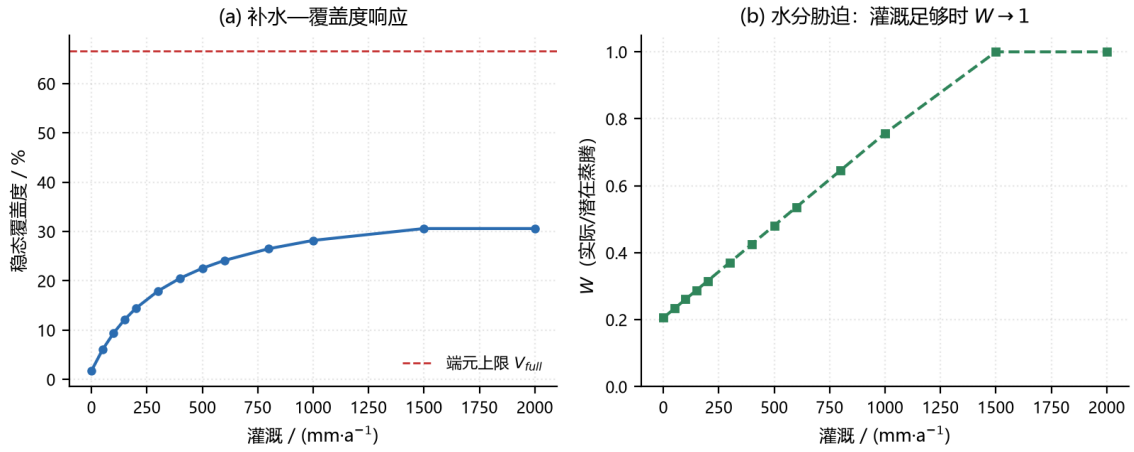


图 5 (a) 补水—稳态覆盖度：单调、凹、有上界；(b) 水分胁迫 W 随灌溉上升并趋近 1

检查	结果	判定
容量 30 mm 与 150 mm 下、300 mm 灌溉的稳态 V	完全相同（差 0.00 pp）	未通过
批次—年中 $W = 1$ 的比例	20.5%	通过

表 14 水分约束是否真在起作用。容量放大 5 倍而 V 不变，说明该灌溉水平下系统是“需求受限”而非“供给受限”

5.2 任务二 M2：工程实现几乎无可挑剔

5.2.1 目标值与约束

检查	结果	判定
净现成本（明细求和 vs 报告）	25 349 978.55 vs 25 349 978.55，相对差 5.9×10^{-11}	通过
毛支出	68 927 280（报告同值）	通过
新增面积	300 ha（报告同值）	通过
9 类约束余量	年度预算 14 976；总预算 11 072 720；年水 449 810；月水 9 114；劳动力 6 478；土地 881；面积 50；PV 500；整数块误差 0	通过
资金比例和	与 1 的偏差 4×10^{-11}	通过

表 15 目标可复现 + 约束零违反（全部余量为正 = 没有一条约束被违反）

5.2.2 最优性证据

检查	结果	判定
情景数	29（base、reference、6 个 frontier、其余敏感性）	—
全部可行	是	通过
MIP gap	最大 0.200%，中位 0.160%	通过
对偶界（成本最小化）	可行值从未低于下界（越界量 0）	通过
对偶界（生态最大化）	可行值未超过上界（余量 −1.90，安全侧）	通过

表 16 MIP 最优性证据。gap 恰好卡在 0.2% 的设定容差上，说明求解器是“到容差即停”，不是“提前放弃”

5.2.3 情景自洽与筛选一致

检查	结果	判定
Pareto 前沿	6 点，成本与生态均单调不减；末段单位生态成本 57 129 元/(ha • 年)	通过
PV 保本电价	0.253—0.312 元/kWh（售价 0.30）；安装年份 1—4 年	通过
安装年份 $\subseteq$ 保本年份	是（第 5 年起保本价 > 0.30，故不再装）	通过
有效面积口径	$\sum$ 面积 $\cdot V_{\text{start}}/K$ 与表中 $effective_ha$ 相对误差 3.9×10^{-10}	通过
决策回放	由 `decisions.csv` 重算年新增面积，误差 0 ha	通过
跨模型参数	r, d, K 与 M1 的差 $< 7 \times 10^{-9}$	通过

表 17 自洽性检查。四组独立计算互相印证，说明 M2 的口径没有漂移

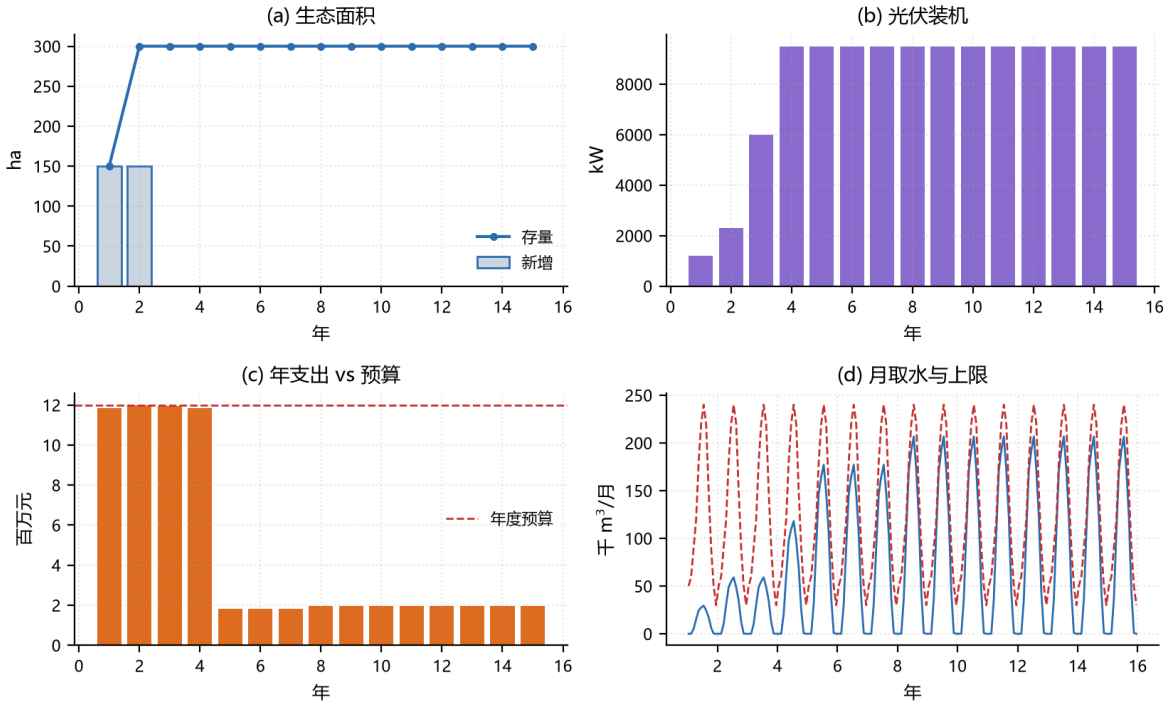


图 6 基准方案：(a) 两年建成 300 ha 后停止扩张；(b) PV 前四年装机至 9.5 MW；(c) 年支出在前四年顶到 12 M 元预算线；(d) 月取水始终低于逐月上限

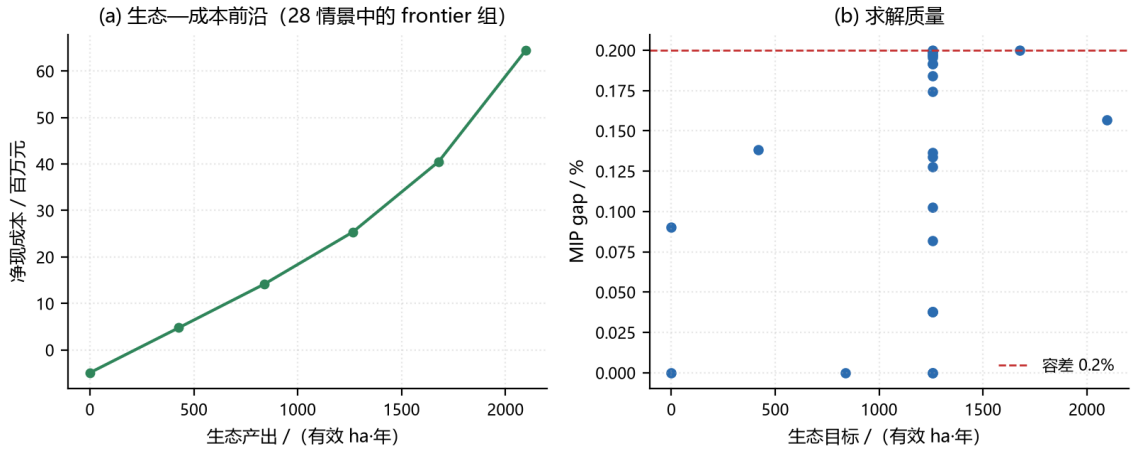


图 7 (a) 生态—成本前沿；(b) 29 个情景的 MIP gap 全部在 0.2% 容差内

5.2.4 瓶颈在哪：一条会影响论文叙事的结论

与 M1 的呼应。 M1 显示“300 mm 灌溉下土壤容量不影响覆盖度”（§5.1.9），M2 显示“年取水用掉 70%、峰值月用掉 95%”。两条合起来说明：**卡住规模的是钱与月分配，不是年水量或土壤库容**。论文因此不该笼统写“水资源约束决定治沙规模”，而应写成“年水量尚有 30% 余量，但 6—8 月的月上限已近饱和（95%）——扩规模的前提是跨季调蓄”。这条比“M1 说水不重要”准确得多，也更有政策含义。

约束	最大利用率	说明
生态目标达成率	100.5%	基准解恰好卡在目标上
总预算	86.2%	未用尽，但已是主导资源
年度预算	99.9%	前四年顶格（余量仅 1.5 万元）
PV 容量	95.0%	接近上限
月取水	94.9%（峰值月）	**月尺度上接近紧**
年取水	70.0%	年总量尚有 30% 余量
生态劳动力	46.0%	中等偏松
土地	26.6%	松

表 18 约束利用率。真正的瓶颈是**生态目标、年度预算与峰值月取水**；年总量与土地还有余量

5.3 任务三 M3：设计检验（尚无数值实现）

用 M1 当前参数（$r = 0.5467$、$d = 0.1073$、$K = 38.08$、$k = 0$、$\eta = 1$、$W = 0.37$）与 M2 情景配置（$\lambda = 0.3$、$u \sim U(0.2, 0.55)$、$v_{\text{crit}} = 0.3K$）检验公式：

检查	结果	判定
转移矩阵	行和误差 1.1×10^{-16}、元素 ≥ 0、吸收态自封	通过
解析 vs 蒙特卡洛	$T = 5$：解析 0.2284 vs MC 0.2287（95%CI $[0.2253, 0.2320]$）	通过
离散化收敛	$n = 100 \to 800$：0.2247、0.2284、0.2312、0.2316；相邻最大变化 1.68%	未通过
$\lambda = 0$ 极限	无灾稳态 $v_\infty = 17.88\% > v_{\text{crit}} = 11.42\%$，不外推退化	通过
参考指标	$\mathbb{E}[\tau] = 9.08$ a、$\rho(Q) = 0.759$、多次事件版 $P(\tau \leq 5) = 0.2419$（二点近似低估 5.9%）	—

表 19 M3 设计检验。三项通过、一项未通过：网格必须取到 $n \geq 400$ 才能把离散偏差压到 1% 以下

实现时的三个建议。 (i) 网格 $n \geq 400$（$n = 200$ 时 $P(\tau \leq 5)$ 偏低约 1.5%）；(ii) 质量前推必须用 $Q^\top$（写成 $Q\boldsymbol{p}$ 会在 $\lambda = 0$ 时“凭空消失”，这条极限检验能抓住）；(iii) 若按数据估计 λ（≥ 12 m/s 的年事件数约 1.5），则 $0 < \lambda < 1$ 不成立，必须用复合泊松而不是二点近似——本次对照显示二点近似低估约 6%。

6 【第五步】检验总结

6.1 核心结论

一句话结论。 M2 是一份可以直接进论文的工程化实现；M1 的机理与守恒关系也站得住，但它的**预测优势未被数据支持**。因此论文应当**把 M1 定位成“机理与情景工具”而不是“预测模型”**：不报“2027 年覆盖度将是 x%”，而报“在灌溉 300 mm 时稳态约 18%，600 mm 时约 24%”（这两条有曲线支撑）。

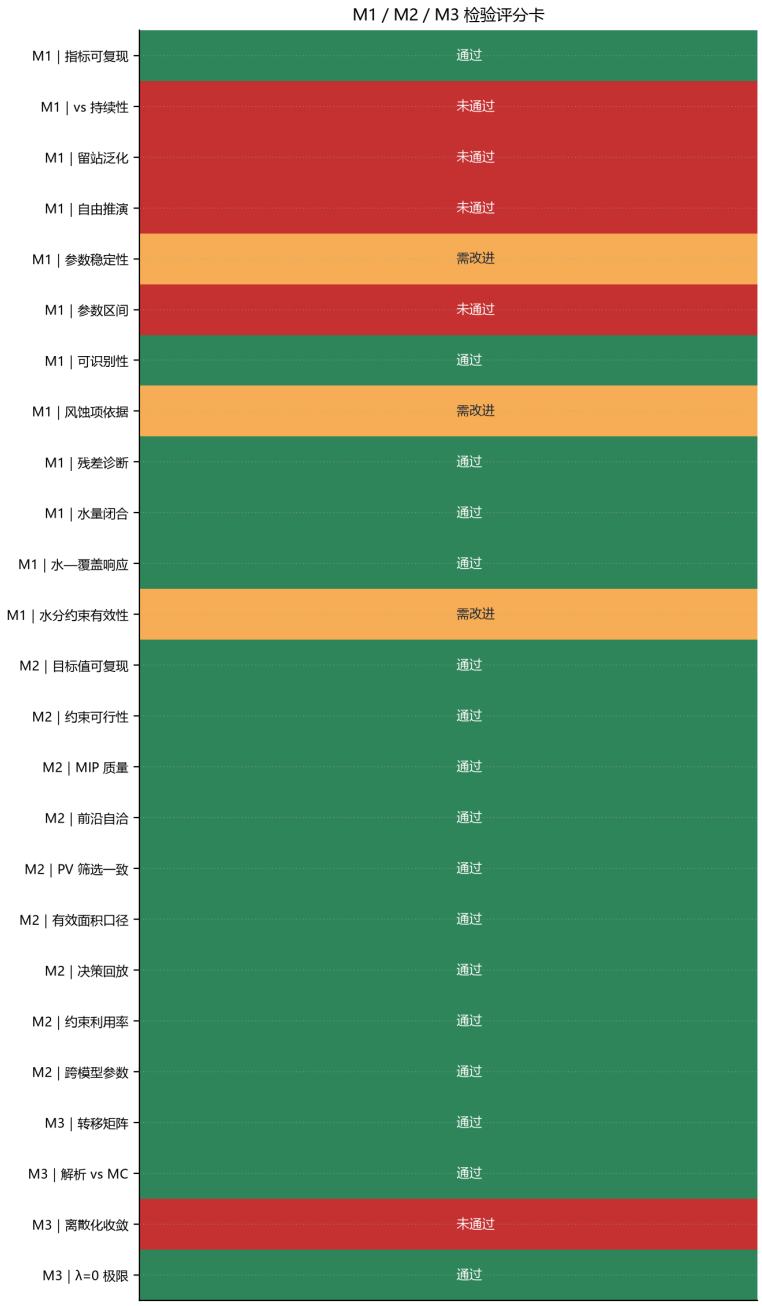


图 8　25 项检验的评分卡（绿＝通过，橙＝需改进，红＝未通过）

模块	检验项	通过	需改进/未通过
M1（12 项）	复现、技能、留站、自由推演、参数、区间、可识别、风蚀、残差、水量闭合、响应曲线、水分约束	7	5
M2（9 项）	目标、约束、MIP、前沿、PV、有效面积、回放、利用率、跨模型	9	0
M3（4 项）	矩阵、解析/模拟、收敛、极限	3	1
合计		**17**	**8**

表 20　分模块统计。M2 全通过，M1 的失败集中在“预测能力”与“样本量”

维度	评分（5 分制）	依据
可复现性	5	指标逐位一致；目标值与明细差 6×10^{-11}；回放误差 0
数值正确性	4.5	水量账闭合到 10^{-7} mm；约束零违反；MIP 对偶界自洽
统计可靠性	2.5	7 个簇 $\rightarrow$ 区间宽 150%；留出期技能为负；5/7 站点为负
结论稳健性	3	M2 前沿单调、情景齐全；但 M1 的 r 区间足以翻转“扩张/衰退”
工程完整性	4.5	29 情景、月水量账、批次继承、筛选与决策一致，超出一般校赛水平

表 21 整体评价：**算得对，但“这个预测能不能信”的答案是不能全信**

6.2 不足与改法

6.3 论文中的呈现建议

1. **正文放三张图**：图 1（拟合与留出，一张图说明“能拟合但外推不占优”）、图 5（补水—覆盖度，M1 最硬的结论）、图 7（生态—成本前沿，回应题干 trade-off）。
2. **用一张检验汇总表**（本报告表 20 的形式）替代大段文字：列“检验项 / 方法 / 判据 / 结果”，一页交代可信度。
3. **把“未通过”写成“限定条件”**：如“由于 7 个站点的整簇自助区间宽达 150%，本文不报告 r 的点估计，只报告稳态覆盖度的区间（18%—24%）”。
4. **明确两处“反直觉但正确”的结论**：土壤库容不是瓶颈、而峰值月取水已近饱和（M1 容量不敏感 + M2 月利用率 95%）；风蚀在年尺度未检出（MDE 0.85）。这两条写清楚，比“什么都显著”更可信。
5. **M3 若来不及实现**，就把本报告的四项设计检验写成“实现前的验证清单”，并给出 $n \geq 400$ 与 $Q^{\top}$ 两条工程约定——这是零成本加分项。

A 检验项与代码入口

表 23 每项检验对应的函数与数据源

检验	函数	数据源
指标复现	`m1_metrics`	`prediction_pairs.csv`
技能检验	`m1_skill_test`	同上
留站泛化	`m1_holdout`	`holdout_by_site.csv`
自由推演	`m1_holdout`	`free_running_holdout.csv`
参数稳定性	`m1_params`	`model1_results.json`
参数区间	`m1_bootstrap`	`parameter_cluster_bootstrap.csv`
可识别性	`m1_ident`	`model1_results.json`
风蚀项	`m1_wind`	`wind_term_test.csv`

表 23 每项检验对应的函数与数据源

检验	函数	数据源
残差	`m1_residual`	`prediction_pairs.csv`
水量闭合	`m1_water`	`scenario_monthly_water.csv`
响应曲线	`m1_water_cover`	`water_cover_curve.csv`
水分约束	`m1_capacity`	`sensitivity.csv`、`cohorts.csv`
目标复现	`m2_objective`	`annual.csv`
约束可行性	`m2_constraints`	`annual.csv`、`monthly.csv`
MIP 证据	`m2_mipgap`	`scenario_summary.csv`
前沿	`m2_frontier`	同上
PV 筛选	`m2_pv`	`pv_screening.csv`
有效面积	`m2_effective`	`cohorts.csv`、`annual.csv`
回放	`m2_replay`	`decisions.csv`
利用率	`m2_utilization`	`annual.csv`、`monthly.csv`
跨模型	`m2_crossmodel`	两个 JSON
M3 设计	`m3_spec`	两个 JSON（取参数）

B 关键数值速查

表 24 论文可直接引用的检验数字

量	数值	出处
M1 训练/留出 RMSE（x）	0.0516 / 0.0635	表 7
M1 留出 R^2（V 尺度）	0.463	同上
M1 留出期胜率	$7/21 = 33\%$	表 8
M1 留站中位技能分	-0.52（5/7 为负）	表 9
M1 自由推演偏差	-2.40 pp（3 年）	§5.1.3
M1 全样本参数	$r = 0.5467$、$d = 0.1073$、$K = 38.08$	表 10
M1 r 自助区间	$[0.335, 1.168]$（宽 150%）	同上
M1 条件数	375	§5.1.5
M1 水量闭合误差	$< 10^{-13}$ mm（重算 0）	表 13
M1 稳态覆盖度	1.8%（0 mm）→ 24.1%（600 mm）	同上
M2 净现成本	25.35 M 元（重算一致）	表 15
M2 约束违反	0	同上
M2 MIP gap	$\leq 0.200\%$	表 16

表 24 论文可直接引用的检验数字

量	数值	出处
M2 生态目标达成	100.5%；总预算用 86%	表 18
M3 $\mathbb{E}[\tau]$（设计）	9.08 a	表 19
M3 收敛	$n \geq 400$ 才能 $< 1\%$	同上

C 与建模文档的差异记录

表 25 本轮检验发现的表述问题（不影响数值，但影响论文可信度）

编号	差异	建议
D1	`model1_results.json` 写“wind term removed”，易被读成“风蚀无影响”	改为“年尺度未检出（MDE $k \approx 0.$
D2	M1 的 R^2 在 V 尺度、RMSE 在 x 尺度报告	统一说明两个尺度
D3	M2 的“三类资金比例”在 0 支出年留空	论文中注明“比例只在支出年
D4	M2 的 *dual_bound_scaled* 单位随目标变（百万元 / 千 ha • 年）	表注中写
D5	M3 尚未实现	若最终不实现，正文应写“给出可实现的公

编号	问题	机理	改法	预期效果
P1	留出期不如持续性	W 年际变异小，模型只能给慢趋势	不追求一步预测；改报“稳态区间”与“拐点条件”	结论与证据匹配
P2	5/7 站点技能为负	站点级样本只有 3 个留出点	用年际块自助替代站点自助；或做“多站联合”的层级模型	技能分给出不确定区间
P3	r 区间宽 150%，13.7% 的抽样 $r>1$	7 个簇 + 2 参数	明确写“r 的点估计不可用于外推”，只报中位与区间	避免过度解读
P4	YT 主导 r（0.47→0.96）	单点强影响	报“含/不含 YT”两套参数，或做 Cook 距离	参数结论更稳
P5	风蚀“不存在”的措辞	MDE 0.85，无法排除中等效应	改为“未检出，可排除 $k>0.85$”	表述准确