数据预处理报告（修订版）

CQU_MCM 2026 · B 题《治沙是一项精细活》

2026-11-09

摘　要

本报告说明建模数据的来源、质量控制与预处理流程。与上一版相比有三项结构性修正：(1) 气象统一到 NASA POWER 单一口径并保存原响应哈希，不再混用未指定模型的再分析产品；(2) 不再按文献量级人为设定各站输沙率目标，风蚀改以**无量纲侵蚀指数** E 进入模型；(3) 插补、截尾、标准化、共线性筛选**只在训练期拟合**，测试期不参与任何拟合。NDVI 官方 QA 波段仅在两站完整取得，本报告用它量化了 QA 对月最大合成的影响。

S1	气象单一口径	NASA POWER 月度产品，7 参数一次取齐，附 SHA256
S2	单位换算	mm/d→mm/月（按当月天数）；kWh/m²/d→MJ/m²/d
S3	NDVI 有效性	剔除填充值 −3000
S4	替代质控	相对训练期同月气候态 $\|z\| > 3$ 标记可疑
S5	月最大合成	同月多期取最大，抑制云与阴影
S6	覆盖度换算	像元二分，固定端元 0.05 / 0.85
S7	侵蚀指数	Lettau 单位宽度通量，训练期均值归一
S8	ET_0	Hargreaves 原式，R_a 按纬度与日序计算
S9	湿度归一	根区湿度按训练期 5%/90% 分位线性归一
S10	时间切分	训练 2015-01—2022-12；测试 2023-01—2024-12
S11	缺失处理	站内线性插值（限 3 期）+ 训练期同月气候态
S12	留痕	面板、特征、统计量、QA 抽样表全部落盘

表 1: *

表 3 预处理流程

P_t	月降水量	mm	POWER[观测]
$T_t, T_t^{\max}, T_t^{\min}$	月均/最高/最低气温	°C	POWER[观测]
$R_{s,t}$	短波辐射	MJ m^{-2} d^{-1}	POWER[观测]
u_t	10 m 风速	m s^{-1}	POWER[观测]
W_t	根区湿度（0—1）	—	POWER(GWETROOT)[观测]
NDVI_t	归一化植被指数	—	MODIS MOD13Q1[观测]
V_t	植被覆盖度	%	由 NDVI 反演[派生]
E_t	侵蚀指数（无量纲）	—	由 u_t 计算[派生]
$\mathrm{ET}_{0,t}$	参考蒸散	mm	Hargreaves[派生]

表 2: *

表 4 面板变量与来源

TZ	230	0.87%	120	0.0	0.0	
XT	230	0.87%	119	0.0	0.55	
QM	184	15.22%	83	0.08	2.29	

表 3: *

表 1 MOD13Q1 像元可靠性抽样评估（TZ、XT 完整，QM 部分）

NDVI	0	
NDVI_qc	19	
FVC_fixed	19	
P_mm	0	
ET0_mm	0	
GWETROOT	0	

表 4: *

表 2 面板缺失统计

一、数据来源

1.1 气象与地表参数

全部气象要素取自 NASA POWER 官方 API 月度产品（8 个坐标点 × 120 个月，2015—2024）：`PRECTOTCORR`、`T2M`/`T2M_MAX`/`T2M_MIN`、`WS10M`、`ALLSKY_SFC_SW_DWN`、`GWETROOT`。每个请求的 URL、返回字节数与 SHA256 记录在 `Data/raw/nasa_power_verified/manifest_v2.json`，可逐请求复核。**必须强调**：POWER 是同化/再分析产品，不是地名对应站的仪器观测，正文一律称“再分析产品”。

1.2 遥感植被指数

NDVI 取自 ORNL DAAC 的 MOD13Q1 子集服务（250 m、16 天合成），单像元（`kmAboveBelow=0`），因此覆盖度代表**站点尺度**而非区段平均；全部合成期的原始响应保存在本地缓存，可重跑复现。

1.3 工程与文献证据

两份政府/林草部门公开网页（民丰后河坝三期、于田—民丰锁边固沙工程）保存了原文与 SHA256。提取的 5 条工程参数（芦苇方格 1.5 m；果树密度 66 株/亩 = 990 株/hm^2；成本节约 964 元/亩 = 14 460 元/hm^2；民丰生物治沙 13 万亩；于田工程固沙 10.5 万亩）记录在 `parameters.csv`。使用边界很严格：**节约额不是单价**，**规划面积不是已完成面积**。

二、质量控制

2.1 NDVI 像元可靠性

表 1 显示：TZ、XT 两站 QA>1 的合成期比例均为 0.87%，过滤前后**月最大合成几乎不变**（月均绝对差 0.00 pp，最大 0.55 pp）；QM 站 QA>1 比例 15.2%，过滤后月均差 0.08 pp、最大 2.29 pp。**结论**：对“月最大合成”口径，QA 过滤的边际影响很小（最大合成本身倾向选取最清晰观测），但对单期 NDVI 不可忽略。因此全序列采用替代质控：相对训练期同月气候态 $|z| > 3$ 记为可疑，共标记 19 个站点-月，按缺失处理并插补。

2.2 缺失与异常

原始 8 站 × 120 月 = 960 行的气象字段无缺失；覆盖度经替代质控后缺失 19 个。**不做事先截尾**：本题需要保留沙尘暴等极端月，一律截尾会削弱风蚀与灾害识别；异常值只标记、不删除，标准化用中位数/四分位距抗极端值。

三、派生变量

3.1 植被覆盖度（像元二分）

$$V_t = \mathrm{clip}\left(\frac{\mathrm{NDVI}_t - \mathrm{NDVI}_{soil}}{\mathrm{NDVI}_{veg} - \mathrm{NDVI}_{soil}}, 0, 1\right) \times 100\%, \qquad \mathrm{NDVI}_{soil} = 0.05,\ \mathrm{NDVI}_{veg} = 0.85$$

固定端元便于跨站比较；另以各站训练期 5 端元取固定值是可检验的假设，取得地表分类与纯端元像元后应替换。

3.2 侵蚀指数（无量纲）

Lettau 公式给出的 q 是**单位宽度**质量通量（$\mathrm{kg\ m^{-1}\ s^{-1}}$）：

$$q_t = C\frac{\rho}{g}u_{*t}^2\left(u_{*t} - u_{*T}\right), \qquad u_{*t} = \frac{\kappa u_t}{\ln(10/z_0)}$$

$C = 6.7$、$\kappa = 0.40$、$z_0 = 1$ mm、阈值由 10 m 高度 5 m/s 换算；u_t 为月均风速乘阵风代理 1.8（[情景]，敏感 1.5—2.2）。换算面积模数需“宽度/面积/时长”三个额外定义，**本轮不做**，以免量纲不闭合；改用站内归一的无量纲指数 $E_t = q_t/\overline{q}_{2015—2022}$，只表达相对风蚀强度。

3.3 参考蒸散与水分状态

$$\mathrm{ET}_0 = 0.0023\, R_a\,(T + 17.8)\sqrt{T^{\max} - T^{\min}}\; d_m$$

R_a 为天文辐射（按纬度与日序解析计算），d_m 为当月天数。水分状态直接使用 `GWETROOT`，按训练期 5

四、面板结构与划分

平衡面板 960 行，训练期 768 行（2015-01—2022-12）、测试期 192 行（2023-01—2024-12）。插补气候态、W 归一化分位、E 归一基准、标准化参数、共线性筛选**全部只用训练期**估计。

五、局限

- 8 个坐标点是区域点位，不是等距锁边带样带；塔中为腹地背景点，肖塘与塔中直线距离约 36 km，不能声称“各站均代表边缘”，代表区段边界仍需 GIS 划定。
- NDVI 为单像元、固定端元，官方 QA 仅两站完整；覆盖度适合时序分析，不宜当作地面实测。
- 根区湿度为再分析量，土壤有效水、盐分、地下水位未纳入。
- 输沙量、工程单价、电价、可用水量均为情景假设或部分外部证据，不能当作已测定真值。