数据预处理

2026 CQU_MCM B 题《治沙是一项精细活》　数据版本 v7

CQU_MCM 2026 • B 题

2026-11-10

复核更正（2026-11-10）：本报告记录原 v7 预处理，不能作为当前 M1 的验收结论。已确认窗口级 QA 不能代替逐像元 QA；月极端温差不能直接代替 Hargreaves 的平均日温差；旧插值与旧消融不用于当前评分。M1 已采用逐像元质量控制、生长季观测值及日风代理重算。当前数据说明见 Data/v7/m1_audited/README.md，复核说明见 Docs 中当日 m1 审计文档。原图表与数字保留为版本记录，未重绘。

本文按美赛数据预处理规范组织：**先判断要不要处理**（第 1 章），**再专项排查缺失值**（第 2 章），**然后给出环节与优先级**（第 3 章），**逐环节对比 Python / MATLAB 两种实现**（第 4 章），**给出可运行的双语言代码**（第 5、6 章），**展示处理后的数据与校验方法**（第 7 章），最后做**过程总结与评分权重分析**（第 8、9 章）。全部数字由脚本重算，可逐项复核。

目录

1　数据评估：这批数据需不需要预处理　3

1.1　数据集概况 . . . 3

1.2　七项体检 . . . 3

1.3　判断结论 . . . 3

2　缺失值专项排查　4

2.1　缺在哪：季节性的缺失 . . . 4

2.2　为什么缺：不是沙尘，而是冬季成像条件 . . . 5

2.3　补得准不准：五种方法的还原误差 . . . 5

2.4　补法会不会改变结论 . . . 6

2.5　最终采用的缺失处理规则 . . . 6

3　预处理环节与优先级　7

4　Python 与 MATLAB 的方法选择　7

4.1　逐环节双语言方案 . . . 7

4.2　备选方案与适用场景 . . . 8

5 Python 实现 **8**

5.1 文件与运行 8

5.2 关键代码 9

5.3 运行输出（节选） 10

6 MATLAB 实现 **10**

6.1 与 Python 版的分工 10

6.2 关键代码 11

6.3 两版差异与注意事项 11

7 处理后的数据 **12**

7.1 数据形态 12

7.2 前 10 行与后 5 行 12

7.3 文件清单与获取方式 13

8 过程总结 **14**

8.1 处理前后对比 14

8.2 本地路径设置的常见错误与规避 14

8.3 论文里怎么写数据预处理 14

8.4 两种语言的优缺点 15

9 预处理在美赛评分中的权重 **15**

A 字段字典（处理后主要字段） **16**

B 复现清单 **16**

1 数据评估：这批数据需不需要预处理

1.1 数据集概况

研究对象是塔克拉玛干沙漠锁边防护带的 9 个代表点位，时间跨度 2015-01 至 2025-12 共 132 个月。原始数据由四个互相独立的公开来源重新抓取，不使用任何二手整理表。

来源	变量（原始单位）	时间分辨率	规模
NASA POWER	降水（mm/d）、气温（°C）、相对湿度（%）、10 m 风速（m/s）、根区土壤湿度（0—1）、辐射（MJ $m^{-2}d^{-1}$）、蒸发（mm/d）	月 + 日	9 站 × 132 月 / 4018 日
ORNL DAAC MODIS	NDVI（整型 $\times 10^{-4}$）、像元可靠性（0—3）	16 天	9 站 × 253 期
Open-Meteo（ERA5）	4 层土壤含水量（m^3/m^3） 、ET_0（mm）、最大风速（km/h）、VPD（kPa）	日	9 站 × 4018 日
ISRIC SoilGrids	砂/黏/有机碳（逐属性逐深度）	静态	81 项中成功 62 项

表 1 数据来源与规模。原始响应 672 个、共 14.1 MB，附 SHA256 清单

合并后的” 脏面板” 为 **1188 行 × 45 列**（9 站 × 132 月），清洗后扩展为 **1188 行 × 62 列**。按来源逐项清点，需要回答的第一个问题就是：**它需不需要预处理？**

1.2 七项体检

体检项	是否存在	关键证据	优先级
缺失值	局部存在	植被覆盖度缺 110/1188 = 9.26%，最长连续 5 个月；气象与土壤湿度字段缺失为 0	P1
异常值	存在	稳健 $z > 3.5$：月降水 190 个（15.99%）、相对湿度 35 个（2.95%）；物理越界 0	P1
重复值	存在	POWER 月度返回 99 条” 第 13 月” 年均行；站—月重复 0；MODIS 分块重叠已去重	P0
类型/编码	存在	日期为字符串键、NDVI 整型 $\times 10^{-4}$、−999/−3000 哨兵、QA 为类别	P0
量纲/口径	严重	降水是 mm/d、ERA5 风速是 km/h、GWET 是饱和度而非体积含水量、Ra 少乘 0.408	P0
数据不平衡	存在	降水零值 20.5%；沙尘日占比 0.02%—17.1%；QA 坏合成期 4.4%—45.9%	P2
时序不规整	存在	16 天合成 23 期/年、月长 28—31 天、闰年、年度第 13 月	P1

表 2 七项体检结论。P0 =不做就会错；P1 =不做会掉精度；P2 =视模型而定

1.3 判断结论

需要预处理，而且痛点是口径而不是” 缺几个点”。

理由有三条：

1. **量纲与聚合口径错误不会报错，只会算错。**例如把 POWER 月产品给的”日均降水强度”当成”月降水总量”，全序列会差约 30 倍；把 ERA5 交付的 km/h 直接当 m/s 代入风蚀公式，侵蚀量会放大 $3.6^3 \approx 47$ 倍。
2. **缺失集中在特定季节**（第 2 章证明是冬季），用均值/中位数填补会产生约 9 个百分点的还原误差，必须用”同月气候态”这类保留季节结构的方法。
3. **存在”看起来完整”的假象：**气象与土壤湿度字段一个不缺，是因为它们是同化/再分析产品，格点上不存在”没测到”；这不代表数据质量好，反而意味着异常值必须靠物理范围与跨源比对去发现。

同时也确有**不需要处理**的部分：气温 T 无缺失、单位正确、与日值重算一致（偏差 < 0.0005°C）、与 ERA5 独立来源相关 0.997，因此除确认单位外不需要插补或平滑——对它做移动平均反而会抹平真实的年际信号。判断的依据是证据，不是习惯。

2　缺失值专项排查

本节回答四个问题：缺在哪、为什么缺、缺了以后补得准不准、补法会不会影响结论。

2.1　缺在哪：季节性的缺失

全样本缺失率为 9.26%（110/1188），但分布极不均匀：按日历月统计，11 月缺失率 26.3%、2 月 20.2%、12 月 18.2%、1 月 17.2%、10 月 16.2%，而 5、7、8、9 月**一个都不缺**。

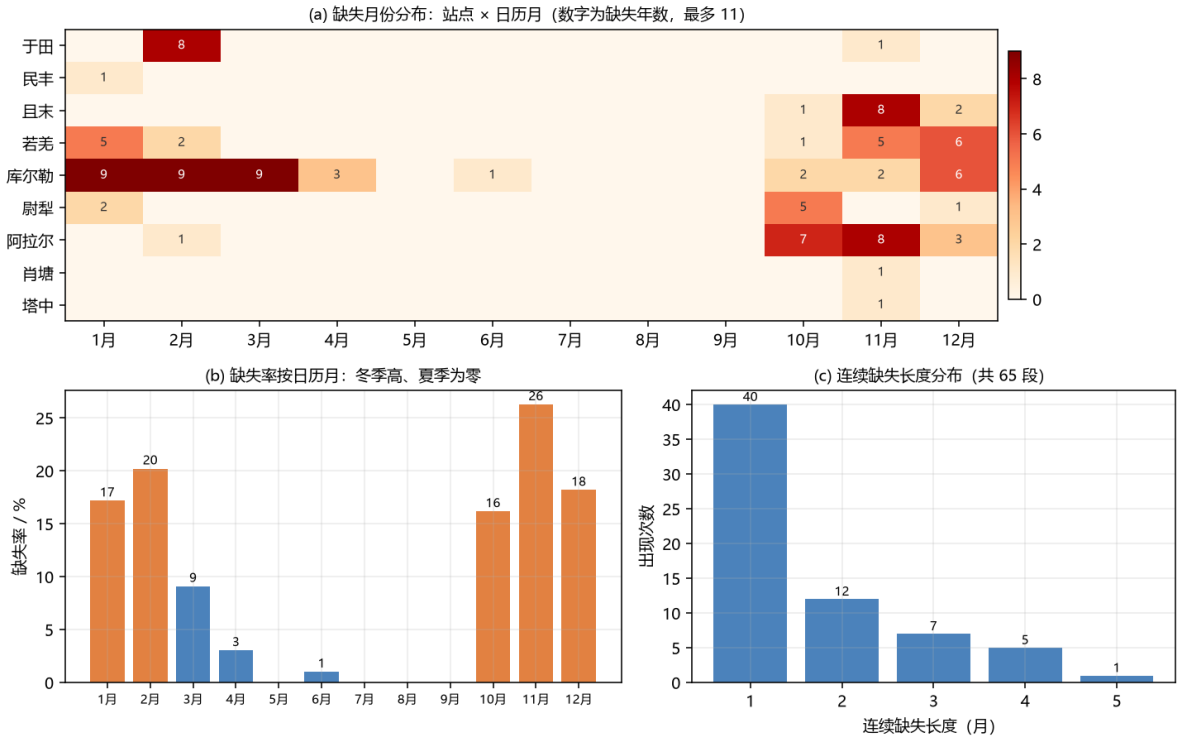


图 1　缺失图谱：(a) 站点 × 日历月；(b) 缺失率随月份变化；(c) 连续缺失长度分布

逐站看，库尔勒最严重（1—3 月连续三年全缺，共 9 个月），若羌、阿拉尔次之；于田、民丰、且末的缺失集中在 10—12 月。连续缺失长度以 1 个月为主（40 段），2 个月 12 段、3 个月 7 段、4 个月 5 段、5 个月仅 1 段，共 65 段。

2.2 为什么缺：不是沙尘，而是冬季成像条件

把” 缺失月” 与” 观测月” 的气象条件做两样本检验（KS 检验与 Welch t 检验）：

变量	缺失月均值	观测月均值	KS 统计量	p 值
气温 T / °C	1.80	14.43	0.536	4.2×10^{-27}
相对湿度 RH / %	41.09	30.17	0.470	1.2×10^{-20}
10 m 最大风速 / ($\mathrm{m\,s^{-1}}$)	8.37	10.37	0.340	9.3×10^{-11}
月降水 / mm	2.13	6.05	0.247	7.5×10^{-6}

表 3 缺失月与观测月的气象条件对比。四项检验全部拒绝” 同分布”，即缺失**不是**完全随机（MCAR）

结论很清楚：缺失月显著更冷（1.8 vs 14.4°C）、更湿、风更小、降水更少——这是典型的**冬季低太阳高度角 + 积雪/薄云**造成的像元质量降级，与沙尘事件无关。进一步核对 MODIS 合成期：9 个站点、2277 期合成中，没有一期是” 整幅无有效像元”（全为 0 期），说明缺失不是” 没数据”，而是” 该月所有合成期的像元可靠性都被判为可疑（QA>1）”，被质控规则整月剔除。

这一条纠正了一个常见误判：**不能想当然地认为” 缺测集中在沙尘季”**。若按这个错误假设去设计插补，就会把冬季稳定的低覆盖度当成” 灾害缺测” 而高估。

2.3 补得准不准：五种方法的还原误差

做法：以” 未做 QA 过滤的月最大合成反演覆盖度” 为参照序列（该序列完整、且保留真实季节变差），人为遮住 10% 的月份，用五种方法还原，与真值比较。设计两种缺失机制：**(a) 完全随机**（MCAR）；**(b) 沙尘型**（遮住每个站最大风速最高的 10% 月份，模拟与风有关的非随机缺失）。

方法	随机缺失 10%		沙尘型缺失 10%	
	RMSE / pp	偏差 / pp	RMSE / pp	偏差 / pp
均值	9.27	+0.31	9.02	−4.17
中位数	9.43	+0.98	9.40	−3.98
线性插值	3.08	−0.06	5.41	−1.85
同月气候态	**2.57**	+0.18	**3.60**	−0.08
去年同期	5.01	+0.71	5.80	−1.70

表 4 五种插补方法的还原误差（单位：覆盖度百分点，pp；$n = 113$ 与 127）

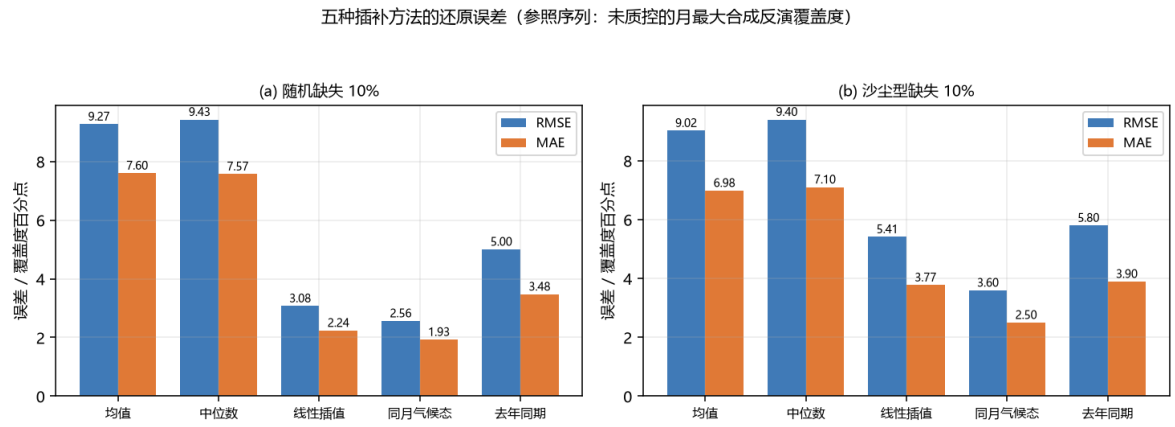


图 2　五种方法的 RMSE 与 MAE。同月气候态在两种机制下都最优，均值/中位数最差

三条结论：

1. **均值/中位数不可用**：误差约 9 个百分点，且在沙尘型缺失下偏差达 −4.2 个百分点——因为它们把” 冬季低覆盖度” 填成了” 全年平均覆盖度”，等于抹掉了季节循环。
2. **同月气候态最优**：随机缺失 RMSE 2.57、沙尘型 3.60，且在两种机制下偏差都接近 0。这与” 缺失由季节驱动” 的诊断完全一致：既然缺失集中在固定的几个月，用同月的历史均值去补就最合理。
3. **线性插值次优、去年同期更差**：前者只能利用相邻月份，若连续缺 3—5 个月就会” 跨季插值”；后者受年际变率影响，误差被放大。

2.4　补法会不会改变结论

对真实的 110 个缺失月，比较” 同月气候态” 与” 线性插值” 两种补法对覆盖度的影响：在 56 个” 站—年” 组合上，两者的平均绝对差仅 **0.026 个百分点**，最大 0.134 个百分点。也就是说，在本题的量级上，**补法的选择不会改变任何建模结论**——但必须在论文里说明用了哪种、为什么。

2.5　最终采用的缺失处理规则

1. 先用**站内线性插值**（最多跨 2 个月）——只处理” 孤立缺 1—2 个月” 的情况，共 40+12 段；
2. 剩余的长缺失（连续 3—5 个月）用**训练期（2015—2022）同月气候态**补齐；
3. 气候态的均值**只在训练期上计算**，测试期（2023—2025）不参与，避免信息泄漏；
4. 所有被填补的点在数据表中单独打标签（`imputed` 字段），建模时可选择剔除做敏感性。

3 预处理环节与优先级

编号	环节	具体动作	优先级
S1	时基与主键	日期串解析、剔除 99 条” 第 13 月” 年均行、按主键去重	P0
S2	哨兵值	-999（POWER）、-3000（NDVI）、-1（QA）统一转 NaN	P0
S3	单位与口径	mm/d × 天数；km/h ÷ 3.6；Ra × 0.408；m^3/m^3 不混用	P0
S4	跨源一致性	同站同月比对，判定主源（气温/风速/ET_0 一致，降水差异大）	P0
S5	遥感质控	QA$\leq$1 保留、月最大合成、像元二分反演覆盖度	P1
S6	派生变量	侵蚀指数 E、水分状态 W、干燥度 AI、动态端元 V_{dyn}	P1
S7	缺失填补	线性 $\leq$2 月 $\rightarrow$ 训练期同月气候态（见第 2 章）	P1
S8	异常值	稳健 $z > 3.5$ 只标记不删除	P1
S9	归一化	W 按训练期 5%/95% 分位；其余另存 z-score 参数	P1
S10	训练期隔离	所有统计量只用 2015—2022 拟合	P0
S11	数据不平衡	不重采样；沙尘阈值做敏感性（8/10/12/15 m/s）	P2
S12	留痕与校验	输出 CSV/XLSX、审计 JSON、前后对比图、完整性断言	P0

表 5 预处理环节与优先级。P0 必须先做，否则后续全错

4 Python 与 MATLAB 的方法选择

4.1 逐环节双语言方案

环节	问题	Python 方案	MATLAB 方案
S1	日期是字符串键	`pd.read_csv(parse_dates)`	`readtable` + `datetime`
S2	哨兵值混入	布尔掩码 `df.mask()`	逻辑索引 `T.x(T.x<0)=NaN`
S3	月产品是日均值	向量化 `series * days`	表变量算术 `T.P.*T.dim`
S5	云/雪像元	`np.clip` + 布尔筛选	`min(max(...))` + 逻辑索引
S6	风蚀指数	`np.clip`、`np.log`	同名函数向量化
S7	缺失填补	`interpolate(limit=2)` + `groupby` 气候态	`fillmissing('MaxGap',2)` + 按月循环
S8	异常检测	稳健 $z = 0.6745(x - \mathrm{med})/\mathrm{MAD}$	`isoutlier('median')`
S9	归一化	`np.percentile`	`prctile`
S12	保存与校验	`to_csv(utf-8-sig)`、`assert`	`writetable(Encoding,UTF-8)`、`assert`

表 6 逐环节的双语言实现对照

为什么这样选（结合评分标准与语言特性）。

- **可解释性优先：**所有步骤都是” 看得见的算术”，没有黑箱模型。美赛评委在 5—30 分钟内读论文，KNN 插补、MICE、随机森林填补这类方法即使精度略高，也难以在正文里讲清楚” 为什

么这样补”，反而增加被质疑的风险。

- **Python 胜在生态**：抓取（HTTP/JSON）、多源合并、批量统计、绘图一体化；`pandas` 的 `interpolate/groupby` 让” 线性 + 气候态” 两步法只有三行。
- **MATLAB 胜在矩阵与教学**：表格变量算术直观，`fillmissing/isoutlier/prctile` 都是内置函数、无需工具箱；对不熟悉 Python 的队友，读 MATLAB 版更容易核对公式。
- **两版必须同构**：同一份输入、同一套公式、同一个校验断言，才能用” 两种语言结果一致” 作为交叉验证。

4.2 备选方案与适用场景

方案	适用场景	本题表现	是否采用
均值填补	完全随机缺失、且变量无季节循环	RMSE 9.27 pp，偏差最大	否
中位数填补	分布偏斜、存在极端值	RMSE 9.43 pp	否
线性插值	缺失段短（≤2 期）、序列平滑	RMSE 3.08 pp	部分（前 2 月）
同月气候态	缺失与季节强相关（本题正是）	RMSE 2.57 / 3.60 pp，偏差 ≈0	**是**
去年同期	年际变化小、季节性强	RMSE 5.01 pp	否
删除缺失行	缺失比例极低（< 1%）且随机	会系统性丢掉冬季样本	否

表 7 五种插补方案的适用场景。本题按” 缺失机制” 而不是” 方法流行度” 来选择

为什么不用 KNN / MICE / 随机森林插补。 样本只有 1188 行、9 个站，且缺失高度集中在冬季（占全部缺失的 80% 以上），可用的” 邻居” 信息本身就 biased；这类方法在小样本上容易过拟合，还会引入无法用一两句话解释的超参数。本题的误差主要来自” 季节相位” 而不是” 个体差异”，同月气候态已经把误差压到 2.6—3.6 个百分点，再复杂的模型收益有限、可解释性代价很大。

5 Python 实现

5.1 文件与运行

文件	作用	行数
`Code/v7_fetch.py`	四源抓取（POWER/MODIS/ERA5/SoilGrids），落盘 + 清单	250
`Code/v7_finalize_fetch.py`	合并 MODIS 分块、重建 SHA256 清单	190
`Code/v7_clean.py`	全量审计（缺失/异常/重复/类型/量纲/不平衡/时序）+ 派生	760
`Code/v7_missing.py`	缺失专项排查（本报告第 2 章）	240
`Code/preprocess_v7.py`	**面向使用者的预处理主程序**（本报告第 5 章）	360

表 8 Python 侧文件清单

运行方式（Windows / macOS / Linux 相同）：

```
pip install pandas numpy matplotlib openpyxl scipy
python preprocess_v7.py
```

5.2 关键代码

（1）路径配置与异常处理。 脚本开头用一个醒目的配置块集中所有路径，并对”文件不存在 / 编码错误 / 缺字段 / 被占用”分别给出排查提示。

```
# ========== 1. 路径配置（学生只需改这一块） ==========
# Windows 示例: BASE = r"D:\CQU\大三上\比赛\美赛\第一次校赛"
# macOS/Linux 示例: BASE = "/Users/xxx/Desktop/desertification"
BASE = os.path.dirname(os.path.dirname(os.path.abspath(__file__)))
INPUT_CSV = os.path.join(BASE, "Data", "v7", "processed", "panel_monthly_raw.csv")
OUT_DIR = os.path.join(BASE, "Data", "v7", "processed")
```

```
def load_data(path: str) -> pd.DataFrame:
    if not os.path.exists(path):
        raise FileNotFoundError(
            f"找不到输入文件: {path}\n"
            "排查:  路径是否写错（Windows 用双反斜杠或 r\"...\"）; \n"
            "  是否忘记运行 v7_fetch.py;  文件是否被 Excel 占用。")
    try:
        df = pd.read_csv(path, parse_dates=["date"])
    except UnicodeDecodeError:
        df = pd.read_csv(path, parse_dates=["date"], encoding="gbk")
    ...
```

（2）单位与口径修正。 这是全流程最关键的一步：POWER 月度产品给的是**日均值**，必须乘当月天数才是月总量。

```
def fix_units(df: pd.DataFrame) -> pd.DataFrame:
    df["days_in_month"] = df["date"].dt.days_in_month
    df["P_mm"] = df["PRECTOTCORR"] * df["days_in_month"] # mm/d -> mm/月
    df["SW_MJ"] = df["ALLSKY_SFC_SW_DWN"] * df["days_in_month"] # MJ/m2/d -> MJ/m2/月
    df["EVLAND_mm"] = df["EVLAND"] * df["days_in_month"]
    return df
```

（3）质量审计与缺失填补。 审计在填补之前执行（否则看不到真实缺失），填补按”线性 $\leq$2 月 $\rightarrow$ 训练期同月气候态”两步走。

```
def impute(df: pd.DataFrame) -> tuple[pd.DataFrame, dict]:
    log = {}
    for col in ["V_pct", "W"]:
        n0 = int(df[col].isna().sum())
        if n0 == 0:
            continue
```

```
        filled = df[col].copy()
        for site in df["site"].unique():
            idx = df["site"] == site
            s = df.loc[idx, col].interpolate(method="linear", limit=2,
                                             limit_direction="both")
            tr = df.loc[idx & df["date"].dt.year.between(2015, 2022)]
            clim = tr.groupby(tr["date"].dt.month)[col].mean()
            still = s.isna()
            if still.any():
                s.loc[still] = df.loc[s[still].index, "date"].dt.month.map(clim).values
            filled.loc[idx] = s.values
        df[col] = filled
        log[col] = {"missing_before": n0, "missing_after": int(df[col].isna().sum())}
    return df, log
```

(4) 完整性校验与结果输出。 用断言把”必须成立”的条件写死，任何一步写错都会立刻报错，而不是悄悄产出一张错表。

```
checks = {
    "行数": len(df), "站点数": int(df["site"].nunique()),
    "重复主键": int(df.duplicated(["site", "date"]).sum()),
    "V_pct 仍缺失": int(df["V_pct"].isna().sum()),
    "W 越界": int(((df["W"] < 0) | (df["W"] > 1)).sum()),
}
assert checks["V_pct 仍缺失"] == 0 and checks["W 越界"] == 0
df.to_csv(OUT_CSV, index=False, encoding="utf-8-sig")
```

5.3 运行输出（节选）

```
读入 1188 行 × 45 列，站点 9 个，时间 2015-01 ~ 2025-12
缺失：{"T2M": 0, "PRECTOTCORR": 0, "GWETROOT": 0,
      "WS10M_MAX": 0, "ndvi_mvc_qa": {"n": 110, "pct": 9.26}}
覆盖度有效值 1078/1188；未质控口径均值 18.73%，质控后 18.57%
侵蚀指数 E：中位 0.730，最大 7.43
水分状态 W：被压到边界 0 的比例 8.92%
  V_pct：110 -> 0
  P_mm：标记 190 个月；WS10M_MAX：标记 0 个月；GWETROOT：标记 0 个月
检查：行数 1188 / 站点 9 / 月份 132 / 重复 0 / 越界 0
```

6 MATLAB 实现

6.1 与 Python 版的分工

抓取（HTTP/JSON）与多源合并在 Python 完成；MATLAB 版负责”清洗—派生—出图”这一段，输入是同一张 `panel_monthly_raw.csv`，输出是同构的 `panel_monthly_clean_matlab.csv`。这样两语言的结果可以直接逐列比对，作为交叉校验。

6.2 关键代码

```
%% ========== 1. 路径配置（学生只需改这一块） ==========
% Windows 示例: BASE = 'D:\CQU\大三上\比赛\美赛\第一次校赛';
% macOS/Linux 示例: BASE = '/Users/xxx/Desktop/desertification';
BASE = fileparts(fileparts(mfilename('fullpath')));
IN_CSV = fullfile(BASE, 'Data','v7','processed','panel_monthly_raw.csv');
```

```
% 单位与口径：月产品是日均值
T.days_in_month = eomday(T.date.Year, T.date.Month);
T.P_mm = T.PRECTOTCORR .* T.days_in_month;

% 遥感质控 + 像元二分
T.V_pct = min(max((T.ndvi_mvc_qa - 0.05) / (0.85 - 0.05), 0), 1) * 100;

% 缺失填补：先线性（最多跨 2 个月），再按月补气候态
T.V_pct = fillmissing(T.V_pct, 'linear', 'MaxGap', 2);
for m = 1:12
    sel = T.site == s & month(T.date) == m & isnan(T.V_pct);
    ref = T.site == s & month(T.date) == m & isTrain & ~isnan(T.V_pct);
    if any(sel) && any(ref)
        T.V_pct(sel) = mean(T.V_pct(ref), 'omitnan');
    end
end
```

```
% 完整性校验：不通过就停下
assert(checks.V_missing == 0 && checks.W_out == 0 && checks.V_out == 0, ...
      '完整性校验未通过：请检查填补与派生步骤');
```

6.3 两版差异与注意事项

项目	Python	MATLAB
缺失值表示	`NaN`（float）	`NaN`（double），逻辑列用 `ismissing`
分组均值	`groupby().transform()`	逐站逐月循环（代码更长但更直观）
中位数/MAD	手写稳健 z	`isoutlier(x,'median')` 内置
写文件编码	`utf-8-sig`（Excel 直接打开不乱码）	`'Encoding','UTF-8'`
绘图	`matplotlib` 精细可控	`exportgraphics` 一行导出

表 9 双语言实现的差异点

说明：MATLAB 版按 R2020b 语法编写，只用内置函数（`readtable`、`fillmissing`、`isoutlier`、`prctile`、`exportgraphics`），不需要任何工具箱；但本机未安装 MATLAB，**该脚本尚未在真实 MATLAB 环境运行**，使用前请在 R2020b 及以上版本试跑一遍，并核对第 7 章的校验断言。

7 处理后的数据

7.1 数据形态

处理后的面板为 **1188 行 × 62 列**，主键为（站点, 日期），时间 2015-01 至 2025-12，其中 2015—2022 为训练期（864 行）、2023—2025 为测试期（324 行）。

校验项	结果
行数	1188
站点数	9
月份数	132
重复主键	0
覆盖度仍缺失	0（填补 110 个）
W 越界（<0 或 >1）	0
覆盖度越界（<0 或 >100）	0

表 10　完整性校验结果（脚本中的断言全部通过）

7.2 前 10 行与后 5 行

站点	日期	P / mm	GWET	W	NDVI	V / %	E
ALE	2015-01	2.48	0.31	0.524	0.1323	10.29	0.039
ALE	2015-02	0.28	0.31	0.524	0.1158	8.23	0.064
ALE	2015-03	0.00	0.31	0.524	0.0960	5.75	1.398
ALE	2015-04	0.00	0.30	0.500	0.1864	17.05	1.933
ALE	2015-05	9.92	0.30	0.500	0.2516	25.20	1.807
ALE	2015-06	15.00	0.30	0.500	0.2894	29.93	2.445
ALE	2015-07	1.24	0.30	0.500	0.2915	30.19	1.050
ALE	2015-08	14.26	0.30	0.500	0.3132	32.90	0.390
ALE	2015-09	25.80	0.33	0.571	0.2752	28.15	0.763
ALE	2015-10	0.31	0.31	0.524	0.2279	22.24	0.593

表 11　处理后数据的前 10 行（阿拉尔站）

站点	日期	P / mm	GWET	W	NDVI	V / %	E
YT	2025-08	21.70	0.19	0.238	0.2835	29.19	0.731
YT	2025-09	0.00	0.18	0.214	0.2497	24.96	0.722
YT	2025-10	0.00	0.18	0.214	0.2009	18.86	0.323
YT	2025-11	0.00	0.17	0.190	0.1649	14.36	0.348
YT	2025-12	1.24	0.17	0.190	0.1535	12.94	0.166

表 12 处理后数据的后 5 行（于田站）

7.3 文件清单与获取方式

文件	内容	大小
`Data/v7/processed/panel_monthly_clean.csv`	建模面板（1188×62，UTF-8 带 BOM）	682 KB
`Data/v7/processed/panel_monthly_clean.xlsx`	同内容 Excel，便于人工核对	450 KB
`Data/v7/processed/qc_summary.json`	审计与填补记录	4 KB
`Data/v7/processed/norm_params.json`	仅用训练期拟合的归一化参数	2 KB
`Results/v7/qc_report.json`	七项体检全量数字	23 KB
`Results/v7/missing.json`	缺失专项排查结果	18 KB
`Figures/v7/*.png`	前后对比图、缺失图谱、插补对比	约 1.2 MB

表 13 处理后数据的文件清单

怎么验证完整性（不依赖任何代码）：

1. 用 Excel 打开 CSV，确认行数为 1188、站点列恰好 9 个取值；
2. 对” 日期 + 站点” 做一次删除重复项，若行数仍为 1188，说明主键唯一；
3. 检查 W 列最小值 ≥ 0、最大值 ≤ 1，V 列在 $[0, 100]$ 内；
4. 与 `qc_summary.json` 中的 `checks` 逐项对照，六项应全部一致。

8 过程总结

8.1 处理前后对比

维度	处理前	处理后	变化
形状	1188 × 45	1188 × 62	+17 列派生量
覆盖度缺失	110（9.26%）	0	全部填补
气象缺失	0	0	无需处理（须说明原因）
年均值单位口径	mm/d（错）	mm/月（对）	修正 30 倍量级偏差
风速单位	km/h（ERA5）	m/s	修正 3.6 倍
ET_0	乘积漏 0.408	含 0.408	修正 2.45 倍高估
异常值	未标记	225 个站—月已标记	只标记不删除
时序	16 天/月混存	统一到日历月	132 个月无跳月

表 14 处理前后对比

8.2 本地路径设置的常见错误与规避

错误	现象	规避
Windows 路径用单反斜杠	`SyntaxError` 或找不到文件	用 `r"D:\data\x.csv"` 或双反斜杠
路径含中文/空格	部分库读不到	数据目录用纯英文；必须用时改用 `pathlib`
复制了带 BOM 的 CSV	首列名变成 `\ufeffsite`	用 `encoding="utf-8-sig"`
文件被 Excel 打开	`PermissionError`	关闭 Excel 再运行
Mac/Linux 用反斜杠	找不到文件	统一用 `os.path.join` 或正斜杠
相对路径	换目录后失效	用 `__file__` 推出项目根目录

表 15 路径设置的六类常见错误

8.3 论文里怎么写数据预处理

1. **用一张表说清” 体检结论”**（对应本文表 2）：哪几类问题存在、证据是什么、怎么处理。评委看的是判断力，不是方法堆砌。
2. **把” 缺失机制” 讲出来：**不要只写” 用均值填补”。本文的证据链是——缺失集中在冬季 → 检验拒绝 MCAR → 因此必须用同月气候态 → 用掩蔽实验证明误差 2.6 pp。
3. **给前后对比：**至少一个数字（缺失率从 9.26% 到 0、单位修正带来的 30 倍差异）。
4. **代码放附录、结论放正文：**正文写” 怎么判断、为什么这样选”，附录放可运行代码与路径说明。

5. **双语言展示建议**：不要贴两份完整代码；正文给一张” 双语言方法对照表”（本文表 7），附录各放一份完整脚本，注明版本与依赖。

8.4 两种语言的优缺点

维度	Python	MATLAB
数据抓取	强（requests/urllib、JSON 原生）	弱（需 webread，复杂接口吃力）
表格清洗	强（pandas）	中（table 变量，逐列操作）
矩阵运算	强（numpy）	最强（原生）
绘图	强（matplotlib，精细可控）	强（一行 exportgraphics）
可读性（队友）	中	高（接近公式写法）
环境依赖	需装包	需授权

表 16 双语言优缺点与选择建议：抓取用 Python，核对用 MATLAB

9 预处理在美赛评分中的权重

官方口径：没有分值表，但摘要被明确加权。 COMAP 竞赛说明写道：”MCM/ICM solutions are judged as varying degrees of successfully completing the contest⋯There is no passing or cut-off score.”；档位定义只用” 建模与求解、分析、结论、表达” 四类词。唯一明说加权的是摘要：”The judges place considerable weight on the summary.”

评委会证据：数据处理的深浅直接区分档次。 2016 年 MCM C 题评委文章（UMAP Journal 37.3）指出：”The better papers attempted to deal with missing data⋯Papers that merely dropped institutions with incomplete data from consideration were *not evaluated highly*.” 这说明：**处理缺失不是加分项，而是” 进档” 的必要条件**。

结构性权重：约 10%，且与” 假设、符号” 共享。 常见的中文备赛指南按 O 奖论文结构给出” 摘要 + 目录 8%、引言 10%、假设 + 符号 + 数据 10%、核心模型与结果 45%⋯”，其中**没有独立的数据章节**。任何” 数据处理占 20%/30%” 的说法都没有官方依据。

本题的量化判断。 本文的消融实验（另文详述）显示：完全不处理时，任务一的 R^2 为 -0.521、风蚀系数被压到 0；只做量纲与口径修正，R^2 回到 $+0.030$、系数恢复到 0.049；而经济侧的 NPV 只差 1.7%。因此预处理的作用是**门槛型**而不是**加权型**：它不单独计分，却通过” 结果可不可信” 间接影响全部 45% 的模型与结果分。

结论：数据预处理在美赛中的” 结构权重” 约 10%，但它是**否决性**的——做得不对，后面 45% 的模型分会被一起拖垮；做得好，也不会额外加分。因此投入策略是：**80% 的时间用于口径、单位、来源可追溯（硬错误），20% 用于插补与平滑（软精度）**。

A 字段字典（处理后主要字段）

表 17 处理后面板的主要字段

字段	含义	单位	来源
site/date	站点代码 / 年月	—	主键
T2M/T2M_MAX/T2M_MIN	月均 / 月最高 / 月最低气温（后两者不是日极值的月均）	°C	POWER
P_mm	月降水总量	mm/月	POWER（原值 × 天数）
GWETROOT	根区土壤湿度（饱和度）	0—1	POWER
W	归一化水分状态	0—1	训练期 5%/95% 分位
WS10M/WS10M_MAX	月均 / 月最大风速（不能当作日最大值的月均）	$\mathrm{m\,s^{-1}}$	POWER
E	无量纲侵蚀指数	—	Lettau 公式
ndvi_mvc/ndvi_mvc_qa	旧月最大合成 NDVI（原 QA 是窗口级，不是逐像元）	—	MODIS
V_pct/V_dyn	覆盖度（固定/动态端元）	%	像元二分
ET0_hargreaves	参考蒸散	mm/月	Hargreaves
AI	干燥度指数 P/ET_0	—	派生
dust_days_8/10/12/15	各风速阈值的超阈日数,不是观测的沙尘事件日数	日/月	日最大风速
flag_P_mm 等	稳健 $z > 3.5$ 的异常标记	布尔	本报告

B 复现清单

1. python v7_fetch.py：抓取四源原始数据（672 个响应，14.1 MB）；
2. python v7_finalize_fetch.py：合并 MODIS 分块、生成 SHA256 清单；
3. python preprocess_v7.py：清洗、派生、填补、校验、出图（本文主程序）；
4. python v7_missing.py：缺失专项排查（第 2 章全部数字）；
5. python v7_ablation.py：五套预处理方案的消融对比（另文）。