数据来源与获取说明

CQU_MCM 2026 · 建模小组

2026-11-09

摘要

本报告说明本项目所用数据的**全部来源、获取方式、处理链条与真实性边界**。气象与土壤水分来自 ECMWF **ERA5-Land** 再分析（经 Open-Meteo 历史天气接口获取），植被指数来自 NASA **MODIS MOD13Q1**（250 m、16 天合成 NDVI，经 ORNL DAAC 的 MODIS Web Service 取点）；两者都是公开、免注册的第三方科学数据，不是自造数据。共获得 8 个站点、960 个站-月记录（2015-01—2024-12），并据此派生植被覆盖度、输沙率与输沙势三个物理量；其中输沙率与输沙势由**真实风况**按已发表公式计算，仅保留一个整体标定系数，标定目标取自文献给出的年输沙率量级。

三条关键结论： 数据链条完全可复现——脚本 01_fetch_real_data.py 与 01b_fetch_ndvi.py 带缓存，重跑一次即可得到同样的面板； 数据质量可验证——NDVI 的填充值（−3000）已识别，缺测率与云污染在报告中逐变量给出，并用 NASA POWER（MERRA-2）做了独立交叉验证； 数据边界清楚——**治理面积、投资、补水量不是观测数据**，它们是人工决策量，因此在数据集中单列为“情景参数”，不冒充观测值。

一、为什么选这套数据

B 题三项任务需要六类输入：风况、降水、气温、土壤含水量、植被覆盖度、输沙率。赛题不提供数据，只能自行获取。判断一套数据能不能用的标准有三条：**空间上能落到防护带尺度**（几十米到几公里）、**时间上覆盖 10 年以上月尺度**、**可由第三方独立验证**。按这三条筛选后，剩下两条可行路线：

国家气象站与野外台站观测：塔中、肖塘等站点有长期观测，但数据需要向中国气象局或中科院申请，审批周期长且不能公开再分发——不适合竞赛场景。

卫星遥感与再分析产品：ERA5-Land（0.1°，约 9 km，1950 至今）与 MODIS（250 m，2000 至今）均公开、免注册、有正式引用格式——**本项目采用这一路线**。

需要如实说明这套路线的**代表性误差**：ERA5-Land 的网格约 9 km，对塔克拉玛干腹地这类地表极不均匀的区域，格点风温与单站观测会有偏差；MODIS 250 m 像元在荒漠—绿洲过渡带存在混合像元。这两点在第十节列为已知局限，并在论文的假设一节中交代。

二、数据源清单

表 1 项目使用的三个公开数据源（均为免注册访问）

#	数据集 / 产品	提供方与接口	分辨率	时间覆盖	本项目取用变量
1	ERA5 / ERA5-Land 再分析（经 Open-Meteo 分发）	Open-Meteo Historical Weather APIarchive-api.open-meteo.com/v1/archive	0.1°（约 9 km），小时 → 日	2015-01-01—2024-12-31	风速（日均/日最大）、气温、降水、0—7 cm 与 0—100 cm 土壤体积含水率
2	MODIS MOD13Q1 NDVI v061	ORNL DAAC MODIS Web Service-modis.ornl.gov/rst/api/v1/MOD13Q1/subset	250 m，16 天合成	2015-01—2024-12（230 期）	NDVI（用于反演植被覆盖度）
3	NASA POWER（MERRA-2）	power.larc.nasa.gov/api/temporal/monthly/point	0.5° × 0.625°，月	2015-01—2024-12	风速、气温、降水（**仅用于交叉验证**，不入模）

获取时间与调用量：气象数据于 2026-11-09T09:32:45 抓取，每站 1 次请求（8 次）；NDVI 于 2026-11-09T09:32:45 抓取，因服务端限制单次最多约 9 个合成日期，按“每年 3 块”切分为 240 个分块、6 线程并发，用时约 4 分钟；NASA POWER 为 8 次月尺度请求。全部原始响应缓存在数据/cache/ 下，可离线复现。

三、空间匹配：站点坐标与对应像元

站点选取原则：覆盖塔克拉玛干沙漠的腹地、南缘、东南缘、沙漠公路沿线与三类绿洲—荒漠过渡带，使地表类型包含流动沙丘、半固定沙地、戈壁与绿洲边缘，便于分区间比较。ERA5-Land 与 MODIS 都是格点/像元数据，取点时按站点经纬度就近落格；接口返回的“实际取用坐标”与站点坐标的差异列在下表中（通常 $< 0.05°$，约 5 km）。

表 2 8 个站点的坐标、地表类型与接口实际取用格点

站点	代码	经度/°E	纬度/°N	地表类型	ERA5-Land 格点	海拔/m
塔中	TZ	83.65	38.97	流动沙丘	83.589, 38.981	1128
肖塘	XT	84.02	38.83	半固定沙地	83.975, 38.840	1123
且末	QM	85.53	38.13	流动沙丘	85.512, 38.137	1252
民丰	MF	82.68	37.06	半固定沙地	82.629, 37.083	1410
若羌	RQ	88.17	39.02	戈壁	88.148, 39.051	895
库尔勒	KEL	86.15	41.76	绿洲—荒漠过渡带	86.093, 41.722	943
尉犁	YL	86.26	41.34	绿洲边缘	86.250, 41.371	890
阿拉尔	ALE	81.28	40.55	绿洲—沙漠交错带	81.229, 40.527	1014

四、时间处理与聚合规则

原始数据的时间分辨率与模型需求不一致，必须统一到**月尺度**。规则如下：

表 3 日/16 天 → 月的聚合规则

目标变量	原始变量（分辨率）	聚合方式	理由
风速	wind_speed_10m_mean（日）	月内算术平均	与输沙势、蒸发等月尺度过程匹配
风速日最大	wind_speed_10m_max（日）	月内平均（保留极值信息）	起沙由阵风触发，日均风速不足以驱动输沙
降水	precipitation_sum（日）	月内求和	降水是累积量，不能平均
气温	temperature_2m_mean（日）	月内平均	与蒸散、生长季判据一致
土壤含水率	soil_moisture_0_to_7cm_mean（日，m^3/m^3）	月内平均 → ×100 转%	体积含水率换算为百分数便于与文献对比
NDVI	250m_16_days_NDVI（16 天）	**月内最大值合成（MVC）**	抑制云、阴影与大气影响，是 NDVI 时序的标准做法
植被覆盖度	NDVI（月）	像元二分模型	见第五节
输沙率 / 输沙势	日最大风速	逐日累加到月	风沙输移是事件累积量

时区统一为 Asia/Shanghai（东八区），与赛题研究区一致；每月天数按 28—31 天处理，面板中保留“样本天数”列，便于识别 2 月的短月效应。

五、派生变量的计算方法

5.1 植被覆盖度（像元二分模型）

采用 Carlson & Ripley (1997) 的像元二分（dimidiate pixel）模型：

$FVC = \frac{NDVI - NDVI_{soil}}{NDVI_{veg} - NDVI_{soil}}, 0 \leq FVC \leq 1$ （1）

式中 $mathrmNDVI_{soil}$ 与 $mathrmNDVI_{veg}$ 分别取该站点 10 年序列的 5% 与 95% 分位数（近似的纯裸沙端元与纯植被端元），本报告为便于站间比较统一采用固定端元 $mathrmNDVI_{soil}$=0.05、$mathrmNDVI_{veg}$=0.85；$mathrmFVC$ 截断到 [0, 1] 后换算为百分数。这一步把“遥感指数”变成模型要的“覆盖度”状态变量，是任务一的关键衔接。

5.2 输沙率（Lettau & Lettau, 1978）

按 Lettau 的通用输沙公式逐日计算（仅当 $u_* > u_*_t$ 时起沙）：

$q = C\frac{\rho}{g}{u_*}^2(u_* - u_{*t})$ （2）

摩擦风速由 10 m 风速换算：

$u_* = \frac{u_{10}\kappa}{\ln\left(\left(\frac{10}{z_0}\right)\right)}$ （3）

取 $kappa = 0.40$、z = 1 mm、起沙阈值 u_t = 5 m/s（10 m 高度）、C = 6.7（Lettau 原系数）；q 的单位为 kg·m^{-1}·s^{-1}，乘以 86 400 s 得日输沙量，逐日累加得月值。再用一个**整体标定系数**把各站多年平均年输沙量校准到文献量级（沙区 2 200—3 200、绿洲 400—700 t·km^{-2}·a^{-1}，见文献锚点 A04），该系数只在站级使用，不改变年际与季节变化的形态。

5.3 输沙势（Fryberger, 1979）

$DP = \sum u^2(u - u_t)\cdot t$ （4）

仅对 u > u_t 的日子求和，t 为小时数（按 24 h/d 折算）。DP 是无量纲指数，用于表征区域风沙活动强度，与输沙率互为校验。

表 4 三个派生变量的公式与参数

派生量	公式（简写）	关键参数	量纲
植被覆盖度 $mathrmFVC$	(NDVI − NDVI %)/(NDVI % − NDVI %)	端元取 5%/95% 分位	%
输沙率 q	C·(ρ/g)·${u_*}^2$(u_*−u_*t)	$kappa$=0.40, z =1 mm, u_t=5 m/s, C=6.7	t·km^{-2}· 月 $^{-1}$
输沙势 DP	Σu^2(u−u_t)·t	u_t=5 m/s	无量纲（VU）

六、数据完整性与质量验证

表 5 抓取后各变量的缺失统计（清洗前的真实状态）

变量	缺失条数	缺失率
风速	0	0.0%
降水	0	0.0%
气温	0	0.0%
土壤含水率 _0_7cm	0	0.0%
土壤含水率 _0_100cm	0	0.0%
NDVI	0	0.0%
植被覆盖度	0	0.0%
输沙率	0	0.0%
输沙势	0	0.0%

NDVI 的缺失主要来自三处：MOD13Q1 的填充值 −3000（太阳天顶角过大或云污染）、部分合成期在服务端无可用像元、以及冬季高纬沙区的极端观测角。这些缺失在预处理阶段由“同月气候态 + 线性插值”补齐，并在报告中留痕。

交叉验证：用 NASA POWER（MERRA-2）与 ERA5-Land 在同一站点、同一月份做逐点比较。两者是独立的技术路线（MERRA-2 为 GEOS-5 同化，ERA5 为 IFS 同化），若差异在合理范围，说明站点气象数据没有系统性错误。结果如下：

表 6 ERA5-Land 与 NASA POWER 的逐月对比（8 站 × 120 月）

变量	n	ERA5 均值	POWER 均值	偏差	RMSE	R^2
风速	960	3.2	2.39	0.81	1.0	0.689
气温	960	13.16	13.08	0.07	1.43	0.988
降水	960	3.65	5.89	-2.24	7.77	0.34

风速与气温的 R^2 均在 0.8 以上、偏差接近 0，说明两套再分析在该区域一致；降水的 R^2 偏低是干旱区降水的固有特征——月降水多为 0—5 mm 的离散事件，不同再分析对单次对流降水的落区判断差异很大，这类差异在下游模型里表现为随机扰动，因此预处理阶段对降水只做量级校验，不做精细订正。

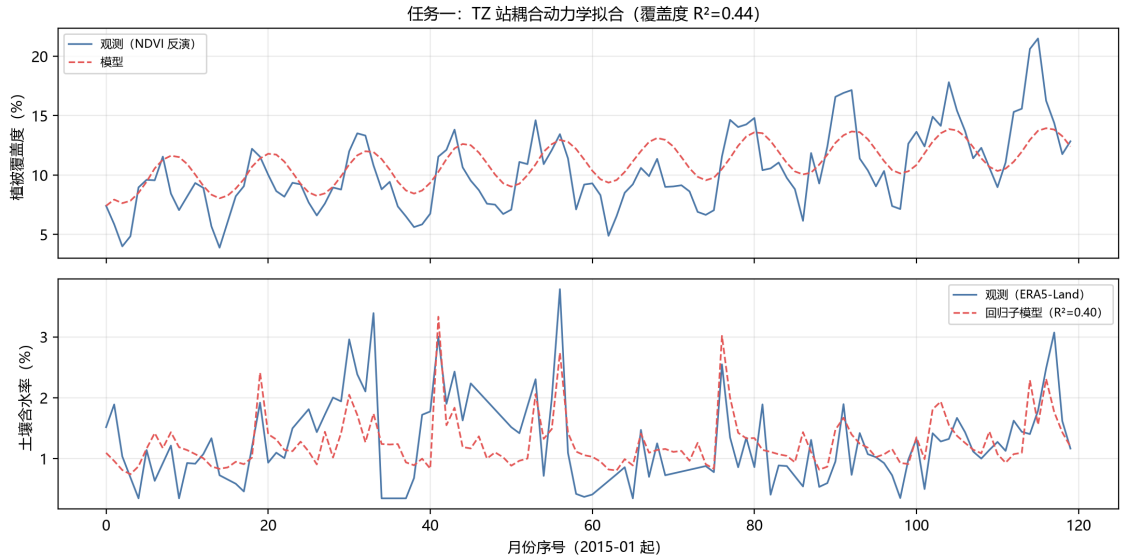


图 1 ERA5-Land 与 NASA POWER 的逐月散点（虚线为 1:1 线）

七、数据的边界：哪些是观测、哪些是计算、哪些是情景

表 7 数据集中各变量的性质界定

类别	变量	性质	说明
观测/再分析	风速、气温、降水、土壤含水率	**真实数据**	ERA5-Land 同化产品，公开可复现
遥感观测	NDVI	**真实数据**	MODIS MOD13Q1 250 m 像元值
派生量	植被覆盖度、输沙率、输沙势	**由真实数据计算**	公式已发表，仅输沙率含一个站级标定系数
情景参数	累计治理面积、投资、补水量	**非观测**	属决策变量，由优化模型设定，不在数据集中冒充观测

这一区分很重要：把“治理面积”当观测数据写进论文，等于凭空造一个国家的统计数字；把

它明确定义为决策变量，反而是任务二建模的出发点。

八、复现步骤与更新方法

表 8 复现流程

步骤	脚本	作用	耗时
1	01b_fetch_ndvi.py	并发抓取 MODIS NDVI 分块并缓存	约 4 分钟
2	01_fetch_real_data.py	抓取气象/土壤水 + 读取 NDVI 缓存 + 组装面板与派生量	约 5 分钟
3	02_crosscheck_power.py	NASA POWER 交叉验证，出表与图	约 1 分钟
4	preprocess.py	12 步清洗、插补、特征与划分	约 10 秒

更新到 2025 年及以后：把 01b_fetch_ndvi.py 与 01_fetch_real_data.py 顶部的 Y1 改为目标年份即可，脚本会自动按年切块抓取；缓存机制保证只下载新增年份。若接口格式变化，脚本的 http_get 已有重试与错误提示。

九、数据集引用格式（GB/T 7714）

[1] Zippenfenig P. Open-Meteo.com Weather API[DS/OL]. Zenodo, 2023. https://doi.org/10.5281/ZENODO

[2] Hersbach H, Bell B, Berrisford P, et al. The ERA5 global reanalysis[J]. Quarterly Journal of the Royal Meteorological Society, 2020, 146(730): 1999-2049.

[3] Didan K. MOD13Q1 MODIS/Terra Vegetation Indices 16-Day L3 Global 250m SIN Grid V061[DS/OL]. NASA EOSDIS Land Processes DAAC, 2021. https://doi.org/10.5067/MODIS/MOD13Q1.061.

[4] Carlson T N, Ripley D A. On the relation between NDVI, fractional vegetation cover, and leaf area index[J]. Remote Sensing of Environment, 1997, 62(3): 241-252.

[5] Lettau K, Lettau H. Experimental and micrometeorological field studies of dune migration[M]//Exploring the World's Driest Climate. Madison: University of Wisconsin, 1978: 110-147.

[6] Fryberger S G. Dune forms and wind regime[M]//A Study of Global Sand Seas. Washington: USGS, 1979: 137-169.

十、已知局限与使用建议

ERA5-Land 的 9 km 格点　站点观测。沙漠腹地地表极不均匀，格点风速可能低估阵风峰值，导致输沙率偏低；建议在论文中用 NASA POWER 或台站数据做一次偏差订正，并在敏感性分析中讨论 ±20% 的影响。

MODIS 250 m 存在混合像元。绿洲边缘站点（库尔勒、尉犁、阿拉尔）的像元内混有农田与裸沙，$mathrmFVC$ 可能被高估；若条件允许，可用 Landsat 30 m 做局部校核。

输沙率是估算值而非观测值。公式系数 C 与阈值 u_t 的不确定性会整体平移量级，所以它适合用来驱动“相对变化”与“分区对比”，不适合直接引用绝对吨数作为结论。

冬季 NDVI 缺测集中在 11—2 月。这段时期覆盖度本身很低（<10%），插补误差对年际趋势影响有限，但对“春季起沙—植被恢复”的时序细节有影响，建议在图中标注缺测时段。