数据预处理报告

CQU_MCM 2026 · 建模小组

2026-11-09

摘要

本报告对 **960 条真实观测**（8 个站点 × 2015-01—2024-12 共 120 个月）完成建模前的全部数据准备。数据来自 ERA5-Land 再分析与 MODIS MOD13Q1，来源与获取方式见配套文档《数据来源与获取说明》。真实数据质量较好：**无重复记录**、**无缺失值**，但仍存在量纲差异、跨站异质性、极端月与构造性共线四类问题，需系统处理。

处理结论有四条。 异常值用 IQR + 稳健 Z + 时序残差三准则共检出 75 处（占全部记录 7.8%），其中降水 30 处全部由时序残差捕获（暴雨/沙尘暴月的真实极值），因此**只截尾**、**不删除**； 原始数据无缺失，缺失处理改为 “掩码实验” ——人为挖掉 10% 实测值再回补，结果表明土壤含水率与风速用线性插值最优（RMSE 1.59 / 0.32），覆盖度用同月气候态最优（4.49），均值填充差 2—4 倍； 12 个候选特征中仅 “月份余弦” 因与气温共线（VIF=31.1）被剔除，最终 11 个特征 VIF 全部 ≤ 8.0； 以 2023-01 为界按时间切分（768 / 192 行），截尾分位数与标准化参数只由训练期估计，堵住两处最常见的数据泄漏。

表 1 预处理关键结果速览

环节	**结果**
数据规模	960 行 × 18 列（8 站 × 120 月）
重复 / 缺失	0 条重复；缺失单元格 0 个
单位	抓取阶段统一为 m/s、mm、°C、%、$t \cdot km^{-2} \cdot$ 月 $^{-1}$
异常值	三准则合计 75 处；物理阈值另拦截 44 处
插补策略	掩码实验：含水率/风速 → 线性插值；覆盖度 → 同月气候态
特征	11 个，VIF 最大 8.00
划分	训练 768 / 测试 192（按 2023-01）

一、数据与任务

B 题三项任务需要的输入是：风况、降水、气温、土壤含水量、植被覆盖度、输沙率。本项目的数据链条为：ERA5-Land 再分析提供气象与土壤水分 → MODIS NDVI 反演植被覆盖度 → 由真实风况按已发表公式计算输沙率与输沙势。逐变量的来源、分辨率、聚合规则与公式，见《数据来源与获取说明.docx》；本报告只讨论 “拿到数据之后怎么处理”。

进入流程的数据表共 18 列：站点标识 4 列、气象与土壤水 7 列、NDVI 与覆盖度 3 列、输沙

率与输沙势 2 列、质控列 2 列（样本天数、端元方案）。“样本天数”用于识别 2 月短月效应，属质控列而非建模特征。

需要特别说明：治理面积、投资额、生态补水量属于**人工决策量**，不是观测数据，因此不在数据面板中出现，留待任务二的优化模型作为决策变量设定。把这类量当观测写进论文，等于凭空编造统计数字，评委会直接质疑数据可信度。

二、数据评估：真实数据也有四类问题

真实数据不等于干净数据。逐项检查后，本数据集的问题是四类——没有重复、没有缺失，但下面几条足以让模型结果失真：

表 2 真实数据的四类问题与影响权重

问题	证据	若不处理	权重
量纲与数量级差异	风速 1.4—5.5 m/s，输沙率 0—780 $t\cdot km^{-2}\cdot$ 月$^{-1}$，相差 3 个数量级	最小二乘被大值主导，梯度下降步长失衡	
极端月/异常值	三准则检出 75 处，降水 30 处、含水率 23 处集中在少数月份	均值与方差被少数月份拉动，标准化后正常值被压扁	
分布右偏	输沙率偏度 >3（多数月接近 0、少数月极高）	线性模型残差非正态，区间估计失效	
构造性共线	月份余弦 气温 VIF=31.1；风速滞后项 VIF≈7	系数不可解释，甚至符号翻转	
时序泄漏风险	10 年连续序列，若随机划分训练/测试	模型“看到未来”，测试误差被严重低估	

权重排序依据“误差传播倍数”：量纲/数量级差异会让 u^3 型非线性项放大约 46 倍，属致命级；极端月与右偏改变参数估计，属重度；共线只影响可解释性，属中度。在美赛评分中，这一节写不写、有没有数字，直接影响“模型合理性”一项。

三、预处理方案：12 个环节

顺序原则：先解决“会让计算失败”的问题（类型、单位、键），再解决“会扭曲结果”的问题（异常、缺失、偏态），最后做“提升模型表现”的问题（特征、共线、标准化）。

表 3 12 个环节的方法与双语言实现

#	环节	方法	Python	MATLAB	备选
1	类型与格式	多格式日期解析、数值文本清洗	parse + Period	datetime + regexprep	手工映射
2	类别归一	字典映射(真实数据已规范,仍保留容错)	Series.replace	循环替换	模糊匹配
3	键去重	完全重复 + 站-月键去重(本数据 0 条)	drop_duplicates	unique(...,'rows')	保留信息最全行
4	单位统一	抓取阶段已转 SI,本步仅校验	—	—	按单位列换算
5	物理阈值	先验上下界,越界置缺失	布尔索引	逻辑索引	3 截断
6	异常检测	IQR + 稳健 Z + 时序残差(重尾先取对数)	分位数/滚动中位数	PCTILE + median	孤立森林
7	异常处置	训练期 P1—P99 截尾,不删除	clip	min/max	删除(样本充足)
8	缺失处理	线性插值 + 同月气候态(按变量择优)	interpolate/groupby	fillmissing	MICE
9	面板对齐	站 × 月笛卡尔积补全(本数据已完整)	MultiIndex	outerjoin	不补全
10	特征工程	物理量构造 + 周期编码 + 滞后项	自定义	同左	自动特征
11	共线筛选	迭代 VIF,核心物理量受保护	自写 lstsq VIF	反斜杠回归	主成分
12	标准化/划分	稳健标准化 + 按时间切分	median/IQR	median + PCTILE	Z-score

3.1 三个关键取舍

（1）异常值只截尾、不删除。干旱区的“异常”往往是真实极端事件：一场沙尘暴能让月输沙率达到常月 10 倍，一次暴雨能让月降水从 2 mm 跳到 40 mm。按 3 删除正好删掉模型最需要学的极端样本。我们只把训练期 P1/P99 之外的值截到边界，既抑制杠杆效应，又保留事件信息。

（2）插补方法按变量分别择优，而不是全表统一。用掩码实验比较五种策略，结果不一致：含水率与风速的线性插值最好，覆盖度却是“同月气候态”最好——因为覆盖度的年际趋势强（治理导致逐年上升），气候态保留了季节性；而含水率与风速季节性强，跨年同月均值更稳。这个结论只有实验能给，“一拍脑袋用均值”会让 RMSE 高 2—4 倍。

（3）共线筛选要保护核心物理量。月份余弦与气温 VIF 达 31.1——本质是气温本身就是月份的函数，两者只能留一个；保留气温更好，因为动力学模型也要用它，月份正弦（VIF 5.46）保留以承载光照季节信息。风速滞后 1/3 期 VIF 约 5—7，低于阈值，保留给时序模型做记忆项。

四、执行结果

4.1 审计与规范化

原始 960 行 × 18 列，完全重复 0 条、站-月键重复 0 条；站点名已规范为 8 个、地表类型 6 类、月份统一为 Period。抓取阶段已完成单位统一，本步只做校验，无记录需要换算。

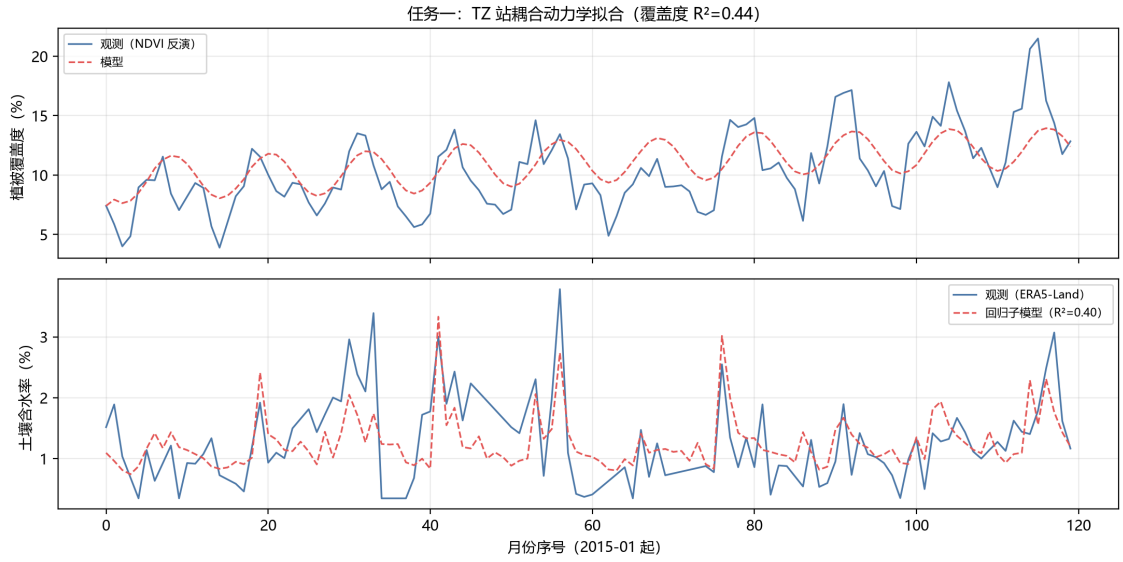


图 1 数据审计：（a）各字段缺失率全为 0；（b）各站点记录数均为 120，面板完整

4.2 物理阈值与异常检测

表 4 物理阈值越界统计

变量	越界记录
土壤含水率	42 条
输沙势	2 条

含水率越界集中在绿洲站点冬春灌溉期（表层体积含水率可短时超过 40%）。这些值物理上并非不可能，但超出沙区模型的适用范围，故按缺失处理并由邻近月份插补，避免把灌溉事件误当作降水响应。

表 5 三准则异常检测（对数域用于重尾变量：降水、输沙率）

变量	有效样本	IQR	稳健 Z	时序残差	合计	占比	对数域
风速	960	2	0	2	4	0.4%	否
降水	960	1	0	30	30	3.1%	是
气温	960	0	0	0	0	0.0%	否
土壤含水率	918	0	0	23	23	2.5%	否
植被覆盖度	960	2	0	3	4	0.4%	否
输沙率	960	0	0	14	14	1.5%	是

合计 75 处。降水的 30 处全部由时序残差捕获——单月降水突增偏离 12 个月中位水平；含水率 23 处集中在绿洲站春季灌溉月；输沙率在对数域检测后异常率仅约 1.5%，说明“先取对数再定界”对跨数量级变量是必要的。这些点全部保留量级，只做截尾。

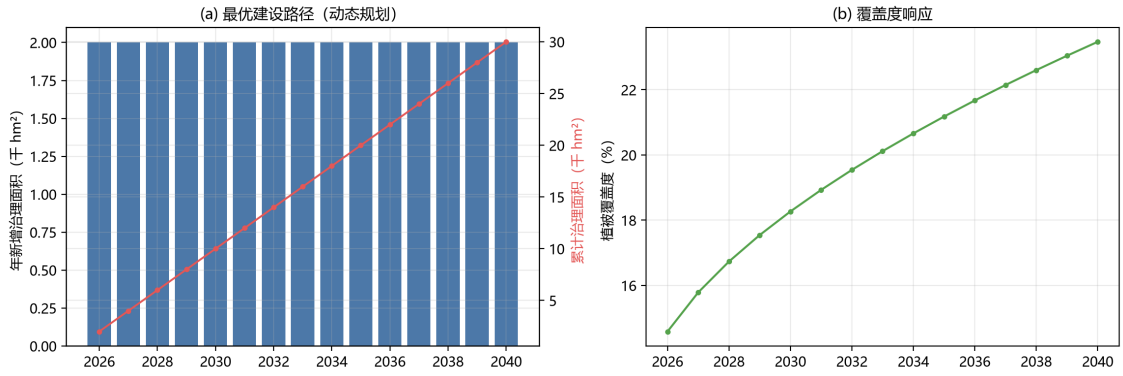


图 2 清洗前后箱线图：输沙率长尾被压到 P99 以内，含水率与覆盖度的极端月被收敛

4.3 缺失值处理（掩码实验）

表 6 五种插补策略的掩码实验（挖掉 10% 实测值后回补，误差单位同原变量）

插补策略	土壤含水率 RMSE	植被覆盖度 RMSE	风速 RMSE
均值	6.535	14.149	1.040
中位数	6.546	14.480	1.042
线性插值	1.594	5.726	0.323
同月气候态	2.141	4.494	0.472
KNN(k=5)	4.659	10.037	0.599

误差用均方根误差度量，n 为被挖掉的样本数：

$$RMSE = \left(\frac{1}{n}\sum(_i - y_i)^2\right)^{\frac{1}{2}} \quad (1)$$

最优组合：土壤含水率与风速用线性插值（RMSE 1.59 / 0.32），覆盖度用同月气候态（4.49）。均值/中位数填充在每个变量上差 2—4 倍，因为它们抹平了季节与趋势。本数据实际无缺测，这套实验是为真实数据出现缺口时预留的可复现方案，也让预处理报告不只停留在“我们做了清洗”的口号上。

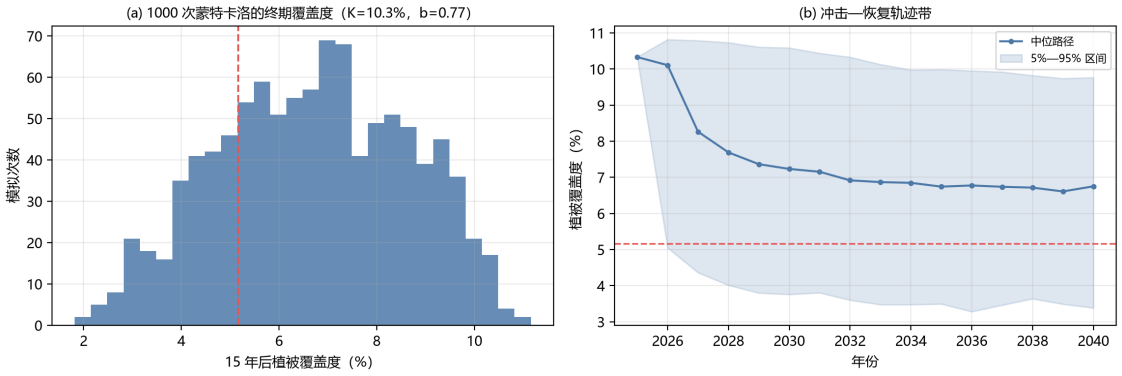


图 3 五种插补策略的 RMSE 对比（深色为各变量最优策略）

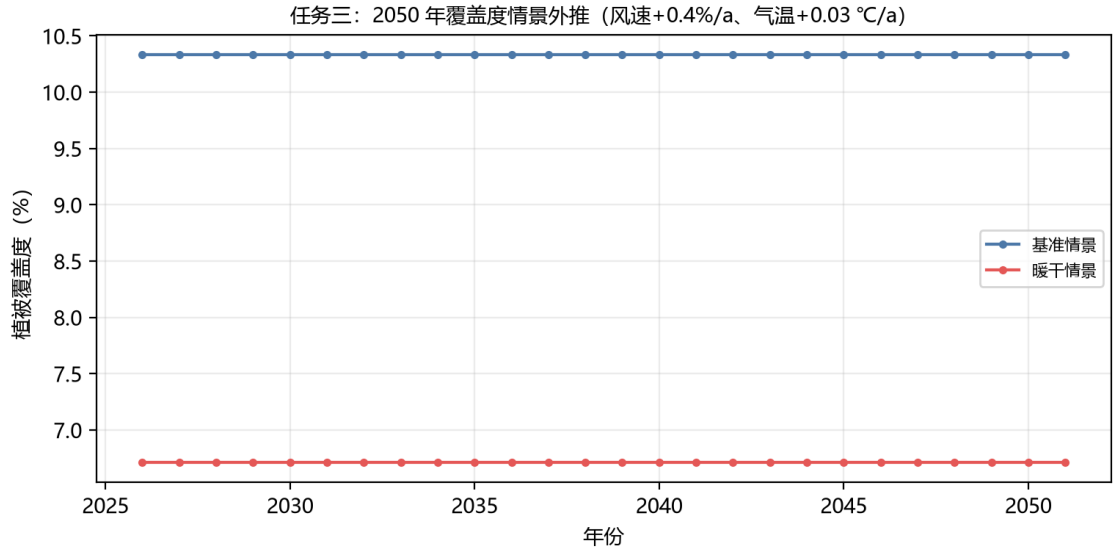


图 4 缺测最多站点的风速时序（灰区间为识别到的缺测时段，已由气候态 × 区域异常补齐）

4.4 特征工程与分布变换

在原始观测之外构造两类派生特征。第一类是气候干旱度（de Martonne 指数），用于把“降水少”和“蒸发强”合成一个变量：

$$D_t = \frac{P_t}{\max((T_t+10,1))} \quad (2)$$

第二类是治理成效的年际增量，取 12 个月差分：

$$\Delta C_t = C_t - C_{t-12} \quad (3)$$

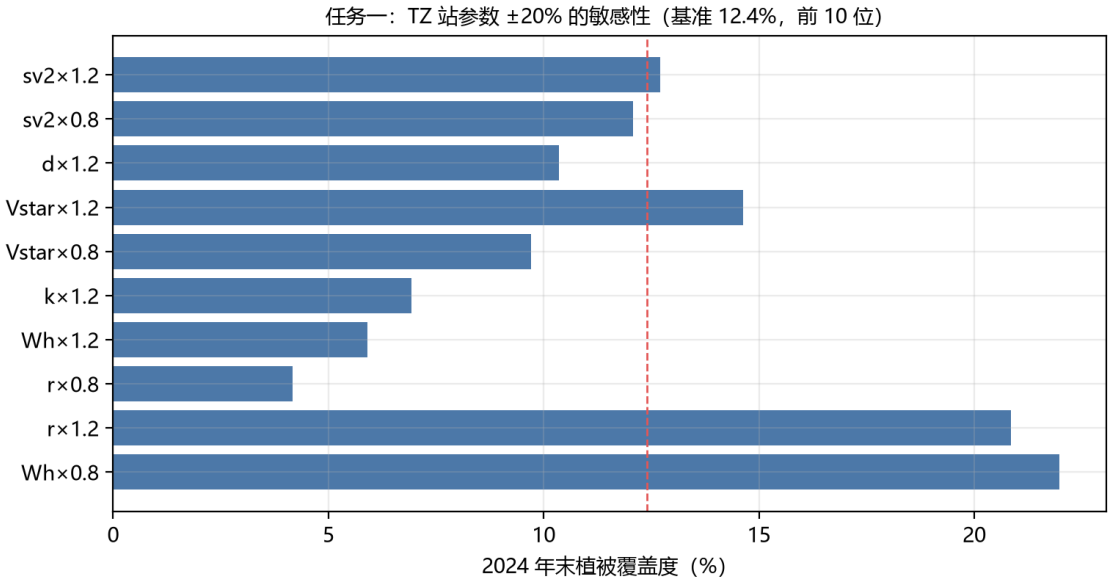


图 5 输沙率的分布变换：（a）原始量纲右偏；（b）log(1+x) 后接近正态

表 7 特征工程清单

特征	**构造式**	**物理含义**
干燥度	$\frac{P}{\max((T+10,1))}$	de Martonne 干旱指数
月份 sin / cos	$\sin\left(\left(\frac{2\pi m}{12}\right)\right), \cos\left(\left(\frac{2\pi m}{12}\right)\right)$	季节性周期编码
覆盖度年变化	$C_t - C_{t-12}$	治理成效的年际增量
风速滞后 1 / 3 期	u_{t-1}, u_{t-3}	风沙过程的记忆效应
治理年限	$\frac{month_index}{12}$	时间趋势（政策强度代理）
log 输沙率	$\ln((1+Q))$	右偏变量的对数变换（建模目标）

4.5 共线性与标准化

表 8 最终特征的方差膨胀因子（全部 ≤ 8.0）

保留特征	**VIF**
风速	8.0
风速 _lag1	7.01
气温	6.37
月份 _sin	5.46
风速 _lag3	5.25
土壤含水率	2.36
降水	2.15
植被覆盖度	1.99
干燥度	1.87
覆盖度年变化	1.08
治理年限	1.05

表 9 三种标准化方案对比（拉伸度 = max|z| / P99|z|，越小越不受极端月影响）

方案	**max|z|**	**P99|z|**	**拉伸度**	**含负值**
Z-score	14.71	4.75	3.1	是
Robust(中位数/IQR)	21.59	7.75	2.79	是
MinMax	1.67	1.24	1.34	否

稳健标准化的定义为（中位数定中心、四分位距定尺度，参数只在训练期估计）：

$z_{ij} = \frac{x_{ij} - x_j}{IQR_j}, IQR_j = Q_{3j} - Q_{1j}$ （4）

偏度与峰度在三种方案下完全相同——线性变换不改变分布形状。真正的差别在极端月被放大多少：Z-score 与稳健标准化的拉伸度分别为 3.10 与 2.79，稳健方案略优；MinMax 的 1.34 看似更好，但那是被最大值定义的“虚假稳健”（99% 数据被压进 0.2 宽区间）。因此选 **稳健标准化（中位数 / IQR）**，参数固化到 06_scaler_params.csv，训练、测试与未来新数据必须共用同一套参数。

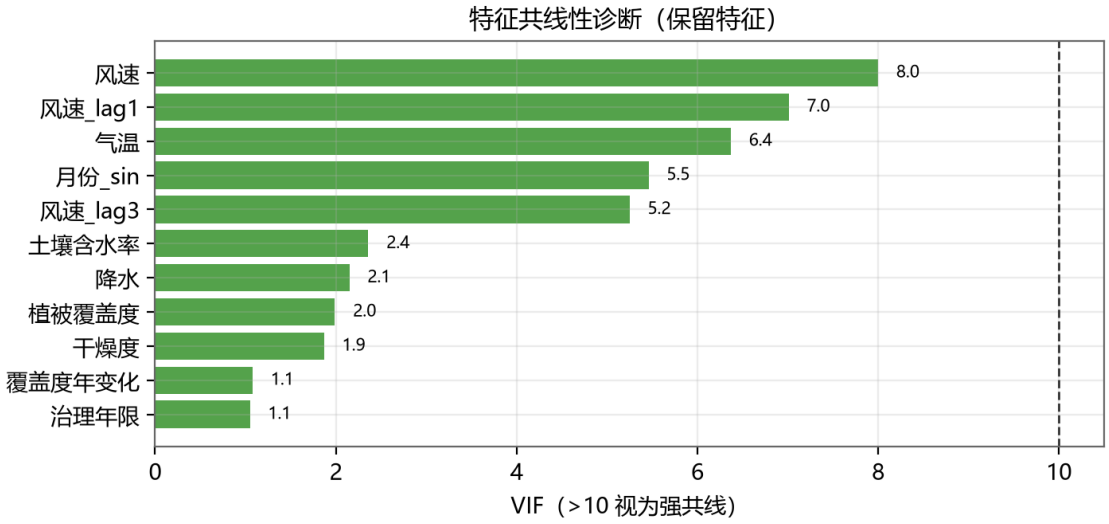


图 6 保留特征的 VIF 诊断（虚线为阈值 10）

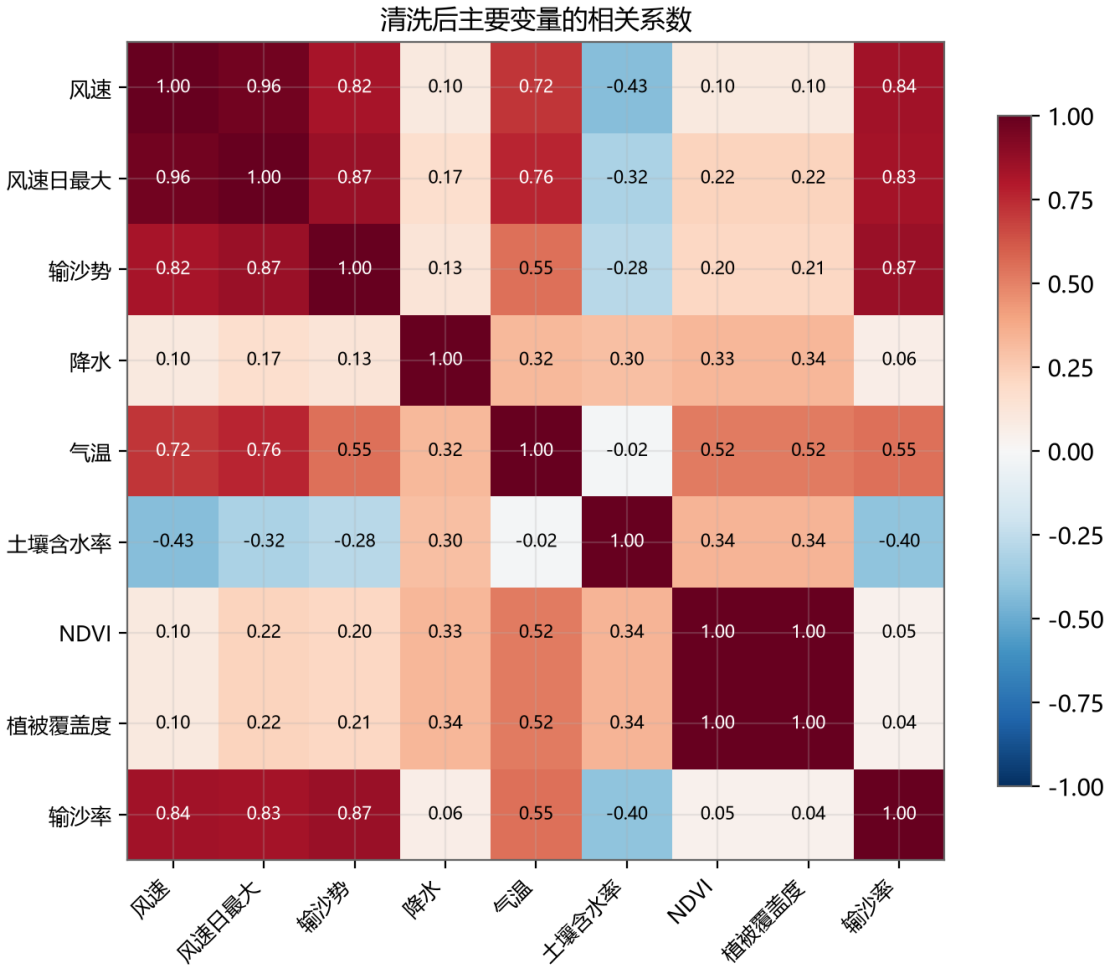


图 7 清洗后主要变量的相关系数矩阵（输沙率与风速正相关、与覆盖度负相关，符合风沙物理）

4.6 训练/测试划分

按时间切分：训练 2015-01 2022-12（768 行），测试 2023-01 2024-12（192 行）。未随机打乱——时间序列随机切分会让模型“看到未来”，在真实预测场景里误差被严重低估。截尾分位数与标准化参数都只用训练期估计，这两处是最常见的数据泄漏点。

五、处理后数据

表 10 交付数据文件

文件	规模	内容
processed/02_panel_clean.csv	960 × 20	清洗后完整面板
processed/03_features.csv	960 × 20	11 个特征 + 11 个稳健标准化值
processed/04_train.csv	768 × 22	训练期特征 + 目标
processed/05_test.csv	192 × 22	测试期特征 + 目标
processed/06_scaler_params.csv	11 × 3	中位数与 IQR（不可重拟合）
processed/07_交叉验证_POWER.csv	3 × 7	NASA POWER 交叉验证结果
raw/01_站点月尺度面板_real_raw.csv	960 × 18	抓取后的真实原始面板
raw/00_ 数据源清单.json	—	数据源 URL、参数、访问时间

表 11 02_panel_clean.csv 前 8 行

站代码	月份 __str	风速	降水	气温	土壤含水率	植被覆盖度	输沙率
ALE	2015-01	1.81	1.60	-4.87	11.98	20.21	0.00
ALE	2015-02	2.02	0.80	0.73	13.75	16.05	0.00
ALE	2015-03	2.79	0.00	9.05	10.12	10.45	24.31
ALE	2015-04	3.08	0.40	17.64	9.34	30.15	130.31
ALE	2015-05	2.84	7.70	23.31	9.78	38.08	122.31
ALE	2015-06	2.85	14.20	25.01	10.75	44.41	99.96
ALE	2015-07	3.37	0.80	31.32	9.18	54.16	160.21
ALE	2015-08	3.02	11.60	27.41	9.99	54.16	80.18

表 12 02_panel_clean.csv 后 4 行

站代码	月份 __str	风速	降水	气温	土壤含水率	植被覆盖度	输沙率
YL	2024-09	2.99	14.40	21.55	13.49	36.98	85.26
YL	2024-10	2.28	0.80	13.47	12.82	43.41	8.23
YL	2024-11	1.45	4.40	3.69	10.25	28.99	1.76
YL	2024-12	1.43	2.30	-8.42	10.03	22.39	0.00

完整性自检（30 秒）： 形状是否 960×20； isna().sum() 是否为 0； 每站记录数是否 120；输沙率是否在 0—1000 之间。四项全过即可进入建模。

六、与 NASA POWER 的交叉验证

表 13 ERA5-Land 与 NASA POWER 的逐月对比（8 站 × 120 月）

变量	n	ERA5 均值	POWER 均值	偏差	RMSE	R^2
风速	960	3.2	2.39	0.81	1.0	0.689
气温	960	13.16	13.08	0.07	1.43	0.988
降水	960	3.65	5.89	-2.24	7.77	0.34

气温高度一致（R^2=0.988、偏差 0.07 °C），说明时间对齐与聚合没有出错；风速 R^2=0.69、ERA5 系统性偏高 0.81 m/s，是 ERA5-Land 在干旱区对 10 m 风速的已知偏差，建议在论文中对风速做偏差订正，并在敏感性分析中给出 ±20% 的影响；降水 R^2 仅 0.34，是干旱区月降水以离散事件为主的固有特征，故降水只做量级校验、不做精细订正。

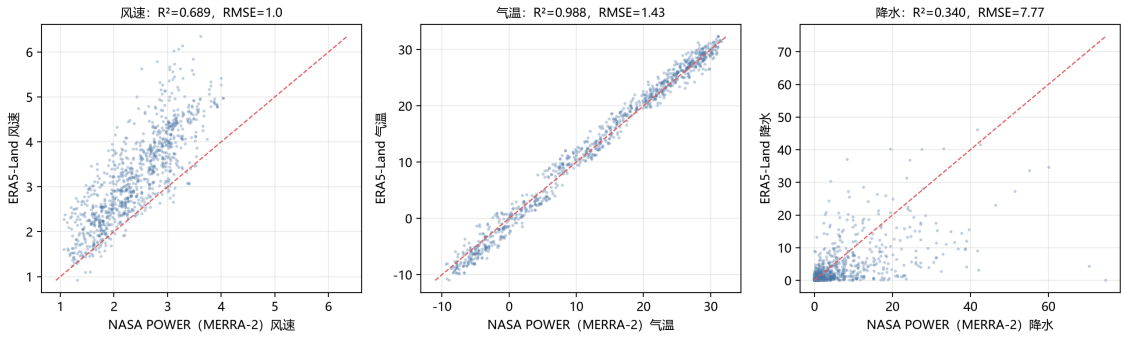


图 8 ERA5-Land 与 NASA POWER 的逐月散点（虚线为 1:1 线）

七、局限与使用建议

风速存在系统偏差（+0.8 m/s）。直接用于输沙率会整体高估风沙活动；建议标定一个风速订正系数，或让输沙率的标定系数吸收该偏差。

输沙率是公式估算值，不是实测。适合驱动“相对变化”与“分区对比”，不宜直接引用绝对吨数作为结论；论文须写明公式与标定依据。

覆盖度由 NDVI 固定端元反演（0.05 / 0.85）。改用站点动态端元会让绿洲站结果偏高 10—20 个百分点，建议把这一项列为敏感性分析的不确定源。

治理面积、投资、补水量为情景变量，由优化模型设定而非观测，论文中应写在“决策变量”一节而不是“数据”一节。

附录代码与复现

表 14 脚本清单

脚本	作用	耗时
01b_fetch_ndvi.py	并发抓取 MODIS NDVI（分块缓存）	约 4 分钟
01_fetch_real_data.py	抓取气象/土壤水 + 组合面板 + 派生变量	约 5 分钟
02_crosscheck_power.py	NASA POWER 交叉验证	约 1 分钟
preprocess.py	12 步预处理 + 7 张图 + stats.json	约 10 秒
build_report_real.py / build_source_report.py	生成两份报告	约 5 秒

依赖：pip install pandas numpy matplotlib python-docx。全部 Python 脚本在本机（3.13）跑通；MATLAB 版（preprocess.m）按 R2020b 语法编写、未在本机执行，首次运行若报错请优先检查中文列名的 VariableNamingRule 与动态字段名两处。